TRƯỜNG ĐẠI HỌC SƯ PHẠM TP.HCM
KHOA CÔNG NGHỆ THÔNG TIN

BÁO CÁO BÀI TẬP NHÓM

Tiền Xử Lý Dữ Liệu

Môn học: Khai Thác Dữ Liệu và Ứng Dụng

Thành viên nhóm: *(Trần Hoàng Đạt — 49.01.104.030)*
(Võ Văn Minh — 50.01.104.090)
(Nguyễn Trần Bảo Thái — 49.01.104.133)

Giảng viên hướng dẫn: *(TS. Nguyễn Tấn Trung)*

Năm học: 2025–2026

Ngày 27 tháng 5 năm 2026

Mục lục

1 Giới thiệu chung **4**

2 Phần 1: Tiền xử lý dữ liệu ảnh **4**

2.1 Mô tả tập dữ liệu 4

2.2 Tải ảnh và thay đổi kích thước 5

2.2.1 Lý do áp dụng 5

2.2.2 Triển khai 5

2.2.3 Kết quả và phân tích 5

2.3 Chuyển đổi ảnh xám 5

2.3.1 Lý do áp dụng 5

2.3.2 Triển khai 5

2.3.3 Kết quả và phân tích 6

2.4 Chuẩn hóa điểm ảnh 6

2.4.1 Lý do áp dụng 6

2.4.2 Triển khai 6

2.4.3 Kết quả và phân tích 6

2.5 Phát hiện cạnh (phần thưởng) 7

2.5.1 Lý do áp dụng 7

2.5.2 Triển khai 7

2.5.3 Kết quả và phân tích 7

3 Phần 2: Tiền xử lý dữ liệu dạng bảng **7**

3.1 Mô tả tập dữ liệu 7

3.2 Xử lý dữ liệu thiếu 7

3.2.1 Lý do áp dụng 7

3.2.2 Triển khai 8

3.2.3 Kết quả và phân tích 8

3.3 Chuẩn hóa dữ liệu 8

3.3.1 Lý do áp dụng . . . 8
3.3.2 Triển khai . . . 8
3.3.3 Kết quả và phân tích . . . 9
3.4 Mã hóa đặc trưng phân loại . . . 9
3.4.1 Lý do áp dụng . . . 9
3.4.2 Triển khai . . . 9
3.4.3 Kết quả và phân tích . . . 9
3.5 Lựa chọn đặc trưng . . . 9
3.5.1 Lý do áp dụng . . . 9
3.5.2 Triển khai . . . 10
3.5.3 Kết quả và phân tích . . . 10

4 Phần 3: Tiền xử lý dữ liệu văn bản (phần thưởng) 10
4.1 Mô tả tập dữ liệu . . . 10
4.2 Tách từ và tách câu . . . 11
4.2.1 Lý do áp dụng . . . 11
4.2.2 Triển khai . . . 11
4.2.3 Kết quả và phân tích . . . 11
4.3 Loại bỏ từ dừng . . . 11
4.3.1 Lý do áp dụng . . . 11
4.3.2 Triển khai . . . 11
4.3.3 Kết quả và phân tích . . . 11
4.4 Rút gọn từ và nguyên dạng hóa . . . 12
4.4.1 Lý do áp dụng . . . 12
4.4.2 Triển khai . . . 12
4.4.3 Kết quả và phân tích . . . 12
4.5 Biểu diễn vectơ văn bản . . . 13
4.5.1 Lý do áp dụng . . . 13
4.5.2 Triển khai . . . 13
4.5.3 Kết quả và phân tích . . . 13

5 Phần 4: Tiền xử lý dữ liệu chuỗi thời gian (phần thưởng) 13

5.1 Mô tả tập dữ liệu . . . 13

5.2 Phân tích cú pháp ngày giờ . . . 14

5.2.1 Lý do áp dụng . . . 14

5.2.2 Triển khai . . . 14

5.2.3 Kết quả và phân tích . . . 14

5.3 Xử lý khoảng trống thời gian . . . 14

5.3.1 Lý do áp dụng . . . 14

5.3.2 Triển khai . . . 14

5.3.3 Kết quả và phân tích . . . 15

5.4 Trích xuất đặc trưng dựa trên thời gian . . . 15

5.4.1 Lý do áp dụng . . . 15

5.4.2 Triển khai . . . 15

5.4.3 Kết quả và phân tích . . . 15

5.5 Lấy mẫu lại chuỗi thời gian . . . 16

5.5.1 Lý do áp dụng . . . 16

5.5.2 Triển khai . . . 16

5.5.3 Kết quả và phân tích . . . 16

5.6 Đặc trưng trễ . . . 16

5.6.1 Lý do áp dụng . . . 16

5.6.2 Triển khai . . . 16

5.6.3 Kết quả và phân tích . . . 17

6 Tổng kết 17

6.1 Những điểm then chốt . . . 17

6.2 Tự đánh giá . . . 17

Tài liệu tham khảo 17

1. Giới thiệu chung

Tiền xử lý dữ liệu là giai đoạn then chốt trong bất kỳ quy trình khai phá dữ liệu hay học máy nào. Dữ liệu thực tế thường không hoàn chỉnh, không nhất quán và chứa nhiễu; nếu không được xử lý thích hợp, chất lượng mô hình phân tích sẽ bị suy giảm đáng kể. Báo cáo này trình bày chi tiết các kỹ thuật tiền xử lý áp dụng cho bốn loại dữ liệu phổ biến:

1. **Dữ liệu ảnh** — tập dữ liệu Fashion-MNIST và New Plant Diseases Dataset;
2. **Dữ liệu dạng bảng** — tập Credit Card Fraud Detection;
3. **Dữ liệu văn bản** — tập IMDB Movie Reviews 50K (phần thưởng);
4. **Dữ liệu chuỗi thời gian** — giá cổ phiếu Apple (AAPL) giai đoạn 2019–2021 (phần thưởng).

Toàn bộ mã nguồn được triển khai bằng Python trong môi trường Jupyter Notebook, sử dụng các thư viện *NumPy*, *Pandas*, *Matplotlib*, *Seaborn*, *scikit-learn*, *OpenCV*, *TensorFlow/Keras* và *NLTK*.

2. Phần 1: Tiền xử lý dữ liệu ảnh

2.1. Mô tả tập dữ liệu

Nhóm sử dụng hai tập dữ liệu ảnh:

- **Fashion-MNIST** — 70.000 ảnh xám kích thước 28×28 điểm ảnh, thuộc 10 danh mục trang phục (áo thun, quần, giày, v.v.). Tập được tải trực tiếp qua `tensorflow.keras.datasets`.
- **New Plant Diseases Dataset** — khoảng 87.000 ảnh màu RGB về lá cây khỏe mạnh và bị bệnh, phân loại thành 38 nhóm, nguồn Kaggle (https://www.kaggle.com/datasets/vipoooool/new-plant-diseases-dataset).

Cả hai tập đều phù hợp với bài toán nhận dạng hình ảnh ứng dụng trong thực tế, từ kiểm soát chất lượng sản xuất đến chẩn đoán bệnh cây trồng trong nông nghiệp.

2.2. Tải ảnh và thay đổi kích thước

2.2.1. Lý do áp dụng

Các ảnh trong cùng một tập dữ liệu thường có kích thước không đồng nhất. Hầu hết các kiến trúc mạng nơ-ron tích chập yêu cầu đầu vào có độ phân giải cố định; do đó, việc chuẩn hóa kích thước là bước bắt buộc trước khi xây dựng mô hình.

2.2.2. Triển khai

Nhóm sử dụng hàm `cv2.resize()` của thư viện OpenCV để thay đổi kích thước ảnh về 128×128 điểm ảnh. Kích thước này được chọn là sự cân bằng giữa độ chi tiết cần thiết và chi phí tính toán — lớn hơn kích thước gốc 28×28 của Fashion-MNIST nhằm giữ lại nhiều thông tin không gian hơn, nhưng nhỏ hơn 224×224 thường dùng với các mạng lớn như ResNet để tiết kiệm bộ nhớ trong giai đoạn thử nghiệm.

2.2.3. Kết quả và phân tích

Ảnh sau khi thay đổi kích thước giữ nguyên tỉ lệ khung hình khi ảnh gốc đã là vuông. Đối với ảnh hình chữ nhật, việc thay đổi kích thước có thể gây biến dạng nhẹ; trong trường hợp này, cần cân nhắc thêm bước cắt (cropping) hoặc thêm viền (padding) trước. Kích thước 128×128 làm giảm kích thước tệp khoảng 75% so với 256×256, đồng thời vẫn duy trì đặc trưng hình dạng tổng thể của lá cây.

2.3. Chuyển đổi ảnh xám

2.3.1. Lý do áp dụng

Ảnh màu RGB có ba kênh, trong khi ảnh xám chỉ có một kênh. Với các bài toán mà màu sắc không mang thông tin phân biệt (ví dụ: nhận dạng hình dạng cơ bản, phát hiện cạnh), chuyển đổi sang ảnh xám giúp giảm số chiều đặc trưng đầu vào, từ đó giảm chi phí tính toán và bộ nhớ.

2.3.2. Triển khai

Hàm `cv2.cvtColor(image, cv2.COLOR_RGB2GRAY)` thực hiện chuyển đổi theo công thức:

$$I_{\text{gray}} = 0{,}299 \cdot R + 0{,}587 \cdot G + 0{,}114 \cdot B$$

Công thức này có trọng số khác nhau cho từng kênh vì mắt người nhạy cảm với màu xanh lá hơn đỏ và xanh dương.

2.3.3. Kết quả và phân tích

Ảnh xám phù hợp với bài toán phân loại hình dạng lá cây vì đặc trưng quan trọng nằm ở kết cấu và viền, không phải màu sắc. Tuy nhiên, với bộ dữ liệu bệnh cây, màu sắc (vàng, nâu, xám) lại là dấu hiệu bệnh lý quan trọng; trong trường hợp này, giữ nguyên ảnh màu là lựa chọn tốt hơn.

2.4. Chuẩn hóa điểm ảnh

2.4.1. Lý do áp dụng

Giá trị điểm ảnh thô nằm trong khoảng $[0, 255]$, khiến gradient trong quá trình huấn luyện mạng nơ-ron có thể dao động lớn và làm chậm hội tụ. Chuẩn hóa đưa giá trị về phạm vi nhỏ hơn, giúp thuật toán tối ưu hóa ổn định hơn.

2.4.2. Triển khai

Hai kỹ thuật được áp dụng:

1. **Chuẩn hóa min-max** — chia toàn bộ giá trị cho 255:

$$x_{\text{norm}} = \frac{x}{255} \in [0,\, 1]$$

2. **Chuẩn hóa theo phân phối chuẩn (standardization)** — trừ giá trị trung bình và chia cho độ lệch chuẩn trên toàn tập:

$$x_{\text{std}} = \frac{x - \mu}{\sigma}$$

   Sau bước này, dữ liệu có trung bình ≈ 0 và độ lệch chuẩn ≈ 1.

2.4.3. Kết quả và phân tích

Chuẩn hóa min-max phù hợp khi dùng hàm kích hoạt *sigmoid* hoặc *tanh*. Chuẩn hóa theo phân phối chuẩn thường được ưu tiên với các mạng sâu dùng *ReLU*. Thực nghiệm cho thấy giá trị trung bình sau chuẩn hóa tiệm cận 0 và độ lệch chuẩn tiệm cận 1, xác nhận tính đúng đắn của phép biến đổi.

2.5. Phát hiện cạnh (phần thưởng)

2.5.1. Lý do áp dụng

Cạnh của vật thể trong ảnh mang thông tin về hình dạng và kết cấu — hai đặc trưng then chốt trong nhận dạng đối tượng. Phát hiện cạnh còn giúp giảm kích thước biểu diễn trong khi giữ lại thông tin không gian quan trọng.

2.5.2. Triển khai

Thuật toán Canny được áp dụng qua `cv2.Canny(gray_image, 100, 200)`. Hai ngưỡng 100 và 200 lần lượt là ngưỡng dưới và ngưỡng trên: các điểm có gradient cao hơn ngưỡng trên chắc chắn là cạnh, thấp hơn ngưỡng dưới bị loại bỏ, còn giữa hai ngưỡng chỉ được giữ nếu kết nối với cạnh đã xác nhận.

2.5.3. Kết quả và phân tích

Kết quả phát hiện cạnh làm nổi bật rõ ràng đường viền lá, các vết nứt và đốm bệnh. Biểu diễn cạnh có thể được sử dụng như một kênh đặc trưng bổ sung (concatenate với ảnh gốc) thay vì thay thế hoàn toàn, để mô hình tiếp cận cả thông tin màu sắc lẫn hình dạng.

3. Phần 2: Tiền xử lý dữ liệu dạng bảng

3.1. Mô tả tập dữ liệu

Tập dữ liệu **Credit Card Fraud Detection** (ULB, Kaggle) gồm 284.807 giao dịch thẻ tín dụng với 31 thuộc tính: `Time`, `Amount`, V1–V28 (các thành phần chính thu được qua phân tích thành phần chính để bảo vệ thông tin cá nhân), và `Class` (0 = hợp lệ, 1 = gian lận). Tỉ lệ giao dịch gian lận rất thấp, chỉ khoảng 0,17%, tạo ra bài toán phân lớp mất cân bằng nghiêm trọng.

3.2. Xử lý dữ liệu thiếu

3.2.1. Lý do áp dụng

Dữ liệu thực tế thường chứa giá trị thiếu do lỗi hệ thống, từ chối cung cấp thông tin, hoặc lỗi thu thập. Nếu không xử lý, nhiều thuật toán học máy sẽ gặp lỗi hoặc cho kết quả thiên lệch.

3.2.2. Triển khai

Tập gốc không có giá trị thiếu; nhóm mô phỏng kịch bản thiếu hoàn toàn ngẫu nhiên (MCAR — *Missing Completely At Random*) bằng cách ngẫu nhiên xóa $\approx 1\%$ giá trị của cột `Amount`. Ba chiến lược điền giá trị thiếu được so sánh:

1. **Điền giá trị trung bình (Mean Imputation)** — nhanh nhưng bị ảnh hưởng bởi giá trị ngoại lệ (outlier).
2. **Điền giá trị trung vị (Median Imputation)** — bền vững hơn với ngoại lệ; phù hợp khi phân phối lệch.
3. **Điền bằng K láng giềng gần nhất (KNN Imputation)** — bảo tồn cấu trúc cục bộ của dữ liệu tốt nhất nhưng chi phí tính toán cao.

3.2.3. Kết quả và phân tích

Biểu đồ phân phối so sánh cho thấy điền giá trị trung bình làm dịch phân phối do ảnh hưởng của ngoại lệ trong cột `Amount`. Điền trung vị tái tạo phân phối gần nhất với dữ liệu gốc. Điền KNN cho kết quả tương đương trung vị trong trường hợp này nhưng yêu cầu thời gian xử lý lâu hơn đáng kể. Nhóm chọn điền trung vị là chiến lược chính thức vì sự cân bằng giữa chất lượng và hiệu quả.

3.3. Chuẩn hóa dữ liệu

3.3.1. Lý do áp dụng

Các đặc trưng V1–V28 đã được chuẩn hóa sẵn thông qua phân tích thành phần chính. Chỉ hai cột `Time` và `Amount` có phạm vi giá trị lớn và cần xử lý riêng để tránh hiện tượng các đặc trưng có biên độ lớn áp đảo quá trình tối ưu.

3.3.2. Triển khai

Ba phương pháp được áp dụng và so sánh:

- **Chuẩn hóa min-max** — ánh xạ về [0, 1]; nhạy cảm với ngoại lệ.
- **Chuẩn hóa Z-score** — trung tâm hóa quanh 0 với phương sai đơn vị.
- **Chuẩn hóa bền vững (Robust Scaling)** — dựa trên trung vị và khoảng tứ phân vị (IQR); ít bị ảnh hưởng bởi ngoại lệ nhất.

3.3.3. Kết quả và phân tích

Đối với cột `Amount` có phân phối lệch phải mạnh và nhiều ngoại lệ, chuẩn hóa min-max dồn phần lớn giá trị về gần 0, mất đi sự tương phản giữa các giao dịch thông thường. Chuẩn hóa Z-score cải thiện hơn nhưng vẫn bị kéo lệch bởi ngoại lệ. Chuẩn hóa bền vững tạo ra phân phối đối xứng nhất và phù hợp nhất cho bài toán phát hiện gian lận — nhóm áp dụng phương pháp này cho `Amount` và Z-score cho `Time`.

3.4. Mã hóa đặc trưng phân loại

3.4.1. Lý do áp dụng

Các thuật toán học máy hầu hết chỉ xử lý được số; đặc trưng dạng chữ hoặc danh mục cần được chuyển đổi thành biểu diễn số trước khi đưa vào mô hình.

3.4.2. Triển khai

Do tập gốc không có biến phân loại (các V1–V28 là kết quả của PCA), nhóm tạo hai biến tổng hợp để minh họa:

- **`amount_tier`** — biến thứ tự (ordinal): phân cụm `scaled_amount` thành 4 mức "Thấp", "Trung bình", "Cao", "Rất cao". Áp dụng **mã hóa thứ tự** (Ordinal Encoding) vì các mức có quan hệ tăng dần có ý nghĩa.
- **`time_period`** — biến danh nghĩa (nominal): phân cụm `scaled_time` thành 4 khoảng thời gian trong ngày. Áp dụng **mã hóa một-nóng** (One-Hot Encoding) vì không có thứ tự tự nhiên giữa các khoảng thời gian.

3.4.3. Kết quả và phân tích

Đối với đặc trưng có số lượng giá trị duy nhất lớn (chẳng hạn mã giao dịch viên), mã hóa một-nóng sẽ tạo ra hàng trăm cột mới, gây hiện tượng "lời nguyền số chiều". Trong tình huống đó, mã hóa theo mục tiêu (Target Encoding) hoặc mã hóa theo tần suất (Frequency Encoding) là lựa chọn phù hợp hơn.

3.5. Lựa chọn đặc trưng

3.5.1. Lý do áp dụng

Không phải đặc trưng nào cũng đóng góp có ích cho mô hình; đặc trưng dư thừa hoặc nhiễu có thể làm giảm độ chính xác và tăng thời gian huấn luyện. Lựa chọn đặc trưng

giúp đơn giản hóa mô hình và nâng cao khả năng khái quát hóa.

3.5.2. Triển khai

Ba phương pháp được so sánh:

1. **Ma trận tương quan** — xác định cặp đặc trưng có tương quan cao ($|r| > 0{,}85$); không tìm thấy cặp nào trong tập này vì V1–V28 là các thành phần chính trực giao theo định nghĩa.
2. **Ngưỡng phương sai** — loại bỏ đặc trưng có phương sai $< 0{,}01$; không có đặc trưng nào bị loại, xác nhận tập đặc trưng đã có chất lượng tốt.
3. **Tầm quan trọng đặc trưng từ Rừng ngẫu nhiên** — 15 đặc trưng quan trọng nhất được hiển thị dưới dạng biểu đồ thanh. Các đặc trưng V17, V14, V12 nổi bật với điểm quan trọng cao nhất, phù hợp với các nghiên cứu trước đây về tập dữ liệu này.

3.5.3. Kết quả và phân tích

Biểu đồ tầm quan trọng đặc trưng cho thấy các thành phần PCA có số thứ tự nhỏ không nhất thiết là quan trọng nhất — điều này hợp lý vì PCA tối đa hóa phương sai, không tối đa hóa liên quan đến nhãn phân loại. Việc giữ lại top-15 đặc trưng theo tầm quan trọng giảm chiều dữ liệu đáng kể mà ít ảnh hưởng đến độ chính xác phân loại, theo nguyên lý Pareto.

4. Phần 3: Tiền xử lý dữ liệu văn bản (phần thưởng)

4.1. Mô tả tập dữ liệu

Tập dữ liệu **IMDB Movie Reviews** (Kaggle) gồm 50.000 bài đánh giá phim tiếng Anh, phân cân bằng giữa hai nhãn tích cực và tiêu cực. Đây là chuẩn mực phổ biến cho bài toán phân tích sắc thái (sentiment analysis). Nhóm sử dụng 1.000 mẫu đầu tiên để thử nghiệm nhằm kiểm soát thời gian tính toán trong môi trường Colab.

4.2. Tách từ và tách câu

4.2.1. Lý do áp dụng

Tách từ (word tokenization) và tách câu (sentence tokenization) là nền tảng của mọi quy trình xử lý ngôn ngữ tự nhiên. Văn bản thô ở dạng chuỗi ký tự liên tục không thể đưa trực tiếp vào các phép tính thống kê hay mô hình học máy; tách từ biến chuỗi thành danh sách các đơn vị ngữ nghĩa (token) có thể đếm và phân tích.

4.2.2. Triển khai

Thư viện NLTK với các hàm `word_tokenize()` và `sent_tokenize()` được sử dụng. NLTK xử lý tốt các trường hợp đặc biệt như chữ viết tắt, dấu chấm lửng và dấu câu phức tạp trong văn bản phim.

4.2.3. Kết quả và phân tích

Một bài đánh giá điển hình trong tập IMDB chứa 8–15 câu và hàng chục token mỗi câu. Tách từ tiết lộ rằng đánh giá phim thường có cú pháp phức tạp, sử dụng nhiều dấu nháy đơn và dấu gạch ngang — các thách thức mà công cụ tách từ đơn giản dựa trên khoảng trắng sẽ xử lý sai.

4.3. Loại bỏ từ dừng

4.3.1. Lý do áp dụng

Từ dừng (the, a, is, in, ...) xuất hiện với tần suất rất cao trong mọi văn bản nhưng không mang thông tin phân biệt sắc thái. Loại bỏ chúng giảm kích thước từ vựng, giảm nhiễu và tăng tốc độ xây dựng mô hình.

4.3.2. Triển khai

Danh sách 179 từ dừng tiếng Anh của NLTK được sử dụng. Nhóm cũng loại bỏ dấu câu bằng danh sách `string.punctuation`. Các token được đưa về chữ thường trước khi so sánh.

4.3.3. Kết quả và phân tích

Số lượng token trên mỗi câu giảm trung bình khoảng 40% sau khi loại bỏ từ dừng và dấu câu. Những từ còn lại chủ yếu là danh từ, tính từ và động từ mang nghĩa — đây

là những yếu tố then chốt quyết định sắc thái tích cực hay tiêu cực của bài đánh giá.

4.4. Rút gọn từ và nguyên dạng hóa

4.4.1. Lý do áp dụng

Các biến thể ngữ pháp của cùng một từ ("running", "ran", "runs") sẽ được coi là ba từ riêng biệt trong không gian biểu diễn nếu không xử lý, gây lãng phí và mất đi tính nhất quán.

4.4.2. Triển khai

Hai phương pháp được so sánh:

- **Rút gọn từ** (Stemming) dùng Porter Stemmer: cắt bỏ hậu tố theo quy tắc, nhanh nhưng đôi khi tạo ra gốc từ không phải từ thực (ví dụ: "happily" → "happili").
- **Nguyên dạng hóa** (Lemmatization) dùng WordNet Lemmatizer: tra từ điển ngữ pháp, chậm hơn nhưng luôn trả về từ có nghĩa (ví dụ: "running" → "run").

4.4.3. Kết quả và phân tích

Bảng 1: So sánh rút gọn từ và nguyên dạng hóa

Từ gốc	Stemming	Lemmatization
running	run	run
flies	fli	fly
happily	happili	happily
better	better	better
cats	cat	cat
studying	studi	study

Nguyên dạng hóa cho kết quả ngôn ngữ học chính xác hơn; nhóm chọn phương pháp này làm bước tiền xử lý chính thức cho tập IMDB vì nội dung đánh giá phim đòi hỏi hiểu đúng nghĩa từ theo ngữ cảnh.

4.5. Biểu diễn vectơ văn bản

4.5.1. Lý do áp dụng

Mô hình học máy chỉ làm việc được với ma trận số; bước vectơ hóa là cầu nối giữa văn bản ngôn ngữ tự nhiên và không gian đặc trưng toán học.

4.5.2. Triển khai

Kỹ thuật TF-IDF (Term Frequency – Inverse Document Frequency) được chọn thay vì túi từ (Bag-of-Words) đơn thuần vì TF-IDF không chỉ đếm tần suất mà còn hạ trọng số của các từ xuất hiện phổ biến trong toàn bộ tập, nhấn mạnh các từ đặc trưng cho từng tài liệu:

$$\text{TF-IDF}(t, d) = \text{TF}(t, d) \times \log\left(\frac{N}{\text{DF}(t)}\right)$$

Thư viện `TfidfVectorizer` của scikit-learn được cấu hình với `max_features=1000` để giới hạn số chiều đặc trưng.

4.5.3. Kết quả và phân tích

Ma trận TF-IDF có kích thước 1000×1000 (1.000 mẫu, 1.000 từ vựng) và là ma trận thưa (hầu hết phần tử bằng 0) vì mỗi bài đánh giá chỉ sử dụng một tập từ nhỏ trong toàn bộ từ điển. Ưu điểm của TF-IDF so với túi từ là giảm tầm quan trọng của các từ phổ biến không mang nghĩa phân biệt (ví dụ: “film”, “movie” xuất hiện trong gần như mọi bài đánh giá phim), tập trung vào các từ chỉ xuất hiện trong một nhóm nhỏ tài liệu và do đó có giá trị phân loại cao hơn.

5. Phần 4: Tiền xử lý dữ liệu chuỗi thời gian (phần thưởng)

5.1. Mô tả tập dữ liệu

Tập dữ liệu gồm dữ liệu giá đóng cửa hàng ngày của cổ phiếu Apple Inc. (mã AAPL) từ ngày 01/01/2019 đến 01/01/2021, được tải về qua thư viện `yfinance`. Tập gồm khoảng 504 ngày giao dịch với các thuộc tính Giá mở cửa, Giá cao nhất, Giá thấp nhất, Giá đóng cửa, Khối lượng giao dịch và Cổ tức điều chỉnh. Giai đoạn này bao gồm sự kiện thị trường lớn là đợt sụt giảm mạnh vào tháng 3 năm 2020 do đại dịch Covid-19.

5.2. Phân tích cú pháp ngày giờ

5.2.1. Lý do áp dụng

Dữ liệu thô thường lưu trữ thời gian dưới dạng chuỗi ký tự với nhiều định dạng khác nhau ("2020-01-15", "15/06/2020", "Jul 4 2020"). Chuyển đổi sang kiểu dữ liệu `datetime` cho phép thực hiện các phép tính số học về thời gian, lập chỉ mục theo thời điểm và trích xuất các thành phần.

5.2.2. Triển khai

Hàm `pd.to_datetime()` với tham số `format='mixed'` xử lý linh hoạt nhiều định dạng ngày. Sau khi chuyển đổi, cột `Date` được đặt làm chỉ mục của khung dữ liệu; các thành phần năm, tháng, ngày, giờ, phút được trích xuất thành các cột riêng để sử dụng trong bước tạo đặc trưng sau.

5.2.3. Kết quả và phân tích

Chỉ mục kiểu `DatetimeIndex` cho phép thực hiện các thao tác đặc thù của chuỗi thời gian như lấy mẫu lại (resampling), dịch chuyển (shift) và cửa sổ trượt (rolling window) một cách tường minh và hiệu quả.

5.3. Xử lý khoảng trống thời gian

5.3.1. Lý do áp dụng

Dữ liệu chứng khoán không có quan sát vào cuối tuần và ngày nghỉ lễ, tạo ra các khoảng trống trong chuỗi thời gian liên tục. Một số mô hình dự báo yêu cầu chuỗi thời gian đều đặn; do đó, cần lấy lại chỉ mục theo phạm vi ngày đầy đủ và điền các giá trị còn thiếu.

5.3.2. Triển khai

Sau khi lấy lại chỉ mục theo phạm vi đầy đủ, năm phương pháp điền khoảng trống được so sánh: điền xuôi (forward fill), điền ngược (backward fill), nội suy tuyến tính, nội suy đa thức bậc 2 và nội suy spline bậc 3.

5.3.3. Kết quả và phân tích

- Điền xuôi/ngược tạo ra các đoạn phẳng, không phản ánh chuyển động giá thực tế.
- Nội suy tuyến tính tạo đường thẳng nối hai điểm biết, đơn giản nhưng bỏ qua độ cong.
- Nội suy đa thức và spline theo sát xu hướng cong của giá tốt hơn, nhưng có thể dao động quá mức (overshoot) khi khoảng trống dài.

Với dữ liệu chứng khoán, điền xuôi hoặc nội suy tuyến tính là lựa chọn phổ biến nhất trong thực tế vì khoảng trống (cuối tuần) ngắn và xu hướng giá ngắn hạn thường tuyến tính.

5.4. Trích xuất đặc trưng dựa trên thời gian

5.4.1. Lý do áp dụng

Thời gian mang nhiều thông tin chu kỳ có giá trị dự đoán: các ngày trong tuần ảnh hưởng đến khối lượng giao dịch; các tháng phản ánh xu hướng theo mùa; ngày nghỉ lễ thường kéo theo thanh khoản thấp trước và sau kỳ nghỉ.

5.4.2. Triển khai

Các đặc trưng được tạo gồm: ngày trong tuần, tháng, mùa (xuân/hạ/thu/đông), cờ ngày nghỉ cuối tuần, cờ ngày lễ liên bang Mỹ và số ngày tính từ đáy Covid (23/03/2020). Đặc biệt, các đặc trưng chu kỳ được mã hóa bằng hàm sin/cos để bảo tồn tính chu kỳ và liên tục:

$$x_{\sin} = \sin\left(\frac{2\pi \cdot t}{T}\right), \quad x_{\cos} = \cos\left(\frac{2\pi \cdot t}{T}\right)$$

trong đó T là chu kỳ (7 cho ngày trong tuần, 12 cho tháng).

5.4.3. Kết quả và phân tích

Biểu đồ phân tán sin/cos cho thấy các điểm dữ liệu phân bố đều trên vòng tròn đơn vị — xác nhận rằng tất cả các ngày trong tuần và tháng trong năm đều được biểu diễn, và khoảng cách giữa ngày 7 (Chủ nhật) và ngày 1 (Thứ Hai) được bảo tồn đúng trong không gian mã hóa.

5.5. Lấy mẫu lại chuỗi thời gian

5.5.1. Lý do áp dụng

Tùy thuộc vào mục tiêu phân tích, tần suất dữ liệu cần được điều chỉnh: hạ tần suất (downsampling) để phân tích xu hướng dài hạn, tăng tần suất (upsampling) để tích hợp với nguồn dữ liệu khác có độ phân giải cao hơn.

5.5.2. Triển khai

Giá đóng cửa hàng ngày được hạ tần suất thành tuần, tháng và quý với các hàm tổng hợp khác nhau (trung bình, lớn nhất, nhỏ nhất, tổng). Đồng thời, dữ liệu ngày được tăng tần suất lên theo giờ bằng nội suy tuyến tính.

5.5.3. Kết quả và phân tích

Biểu đồ so sánh các tần suất cho thấy: tần suất cao (hàng ngày) giữ lại toàn bộ biến động ngắn hạn và nhiễu; tần suất trung bình (tuần/tháng) làm mịn nhiễu và nổi bật xu hướng; tần suất thấp (quý) chỉ phù hợp cho phân tích vĩ mô. Hàm tổng hợp `max` và `min` bảo tồn các đỉnh và đáy quan trọng, trong khi `mean` phản ánh giá trị trung tâm xu hướng.

5.6. Đặc trưng trễ

5.6.1. Lý do áp dụng

Giá cổ phiếu có tương quan tự hồi quy cao — giá hôm nay phụ thuộc nhiều vào giá hôm qua. Đặc trưng trễ (lag feature) và thống kê cửa sổ trượt (rolling statistics) là cầu nối quan trọng khai thác quan hệ này cho các mô hình học có giám sát không chuyên về chuỗi thời gian.

5.6.2. Triển khai

Các đặc trưng trễ $t-1$, $t-2$, $t-5$ (tương ứng 1 ngày, 2 ngày, 1 tuần trước) được tạo. Thống kê cửa sổ trượt 7 ngày và 30 ngày (trung bình động, độ lệch chuẩn) phản ánh xu hướng ngắn và trung hạn. Đặc trưng hiệu (difference) và phần trăm thay đổi được tạo để phản ánh tốc độ biến động. Biểu đồ tự tương quan (ACF) được dùng để xác định số bước trễ phù hợp.

5.6.3. Kết quả và phân tích

Biểu đồ ACF của giá đóng cửa cho thấy tương quan rất cao ở tất cả các bước trễ (không dừng – non-stationary). Ngược lại, biểu đồ ACF của lợi suất hàng ngày cho thấy tương quan gần bằng 0 ở tất cả các bước – nhất quán với giả thuyết thị trường hiệu quả dạng yếu. Điều này cho thấy rằng nếu mục tiêu dự đoán là lợi suất, mô hình sẽ khó khai thác hơn so với dự đoán mức giá tuyệt đối. Bước trễ 1 và 5 được chọn là phổ biến nhất trong tài liệu về dự đoán chứng khoán ngắn hạn.

6. Tổng kết

6.1. Những điểm then chốt

Qua bốn phần thực hành, nhóm rút ra một số nhận định chung:

1. **Không có kỹ thuật tiền xử lý vạn năng.** Mỗi loại dữ liệu và mỗi bài toán đòi hỏi lựa chọn phương pháp dựa trên đặc điểm phân phối, mức độ nhiễu và mục tiêu phân tích cụ thể.
2. **Trực quan hóa là công cụ không thể thiếu.** Biểu đồ phân phối trước và sau xử lý cung cấp bằng chứng trực quan về hiệu quả của từng kỹ thuật, hỗ trợ quá trình ra quyết định.
3. **Chất lượng dữ liệu quyết định chất lượng mô hình.** Một mô hình đơn giản trên dữ liệu được tiền xử lý kỹ lưỡng thường vượt trội hơn mô hình phức tạp trên dữ liệu thô.
4. **Cân bằng giữa hiệu quả và chi phí tính toán.** Các kỹ thuật như KNN Imputation hay Spline Interpolation cho kết quả tốt hơn nhưng tốn kém về tính toán; cần cân nhắc trong triển khai thực tế.

6.2. Tự đánh giá

Tài liệu tham khảo

1. Han, J., Kamber, M., & Pei, J. (2011). *Data Mining: Concepts and Techniques* (3rd ed.). Morgan Kaufmann.
2. Géron, A. (2022). *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow* (3rd ed.). O'Reilly.

Bảng 2: Tóm tắt các kỹ thuật đã triển khai

Phần	Yêu cầu	Kỹ thuật đã thực hiện
Ảnh	Bắt buộc	Tải/thay đổi kích thước, xám hóa, chuẩn hóa, phát hiện cạnh Canny
Bảng	Bắt buộc	Xử lý giá trị thiếu, chuẩn hóa, mã hóa phân loại, lựa chọn đặc trưng
Văn bản	Thưởng	Tách từ/câu, loại từ dừng, rút gọn/nguyên dạng hóa, TF-IDF
Thời gian	Thưởng	Phân tích ngày giờ, xử lý khoảng trống, đặc trưng thời gian, lấy mẫu lại, đặc trưng trễ

3. Pandas Development Team. (2024). *pandas documentation*. https://pandas.pydata.org/docs/

4. scikit-learn Developers. (2024). *scikit-learn User Guide*. https://scikit-learn.org/stable/user_guide.html

5. Bird, S., Klein, E., & Loper, E. (2009). *Natural Language Processing with Python*. O'Reilly.

6. LeCun, Y., et al. (1998). Gradient-based learning applied to document recognition. *Proceedings of the IEEE*, 86(11), 2278–2324.

7. Kaggle Dataset — Credit Card Fraud Detection: https://www.kaggle.com/datasets/mlg-ulb/creditcardfraud

8. Kaggle Dataset — IMDB Movie Reviews: https://www.kaggle.com/datasets/lakshmi25npathi/imdb-dataset-of-50k-movie-reviews

9. Kaggle Dataset — New Plant Diseases: https://www.kaggle.com/datasets/vipoooool/new-plant-diseases-dataset