BÁO CÁO ĐỒ ÁN KHAI THÁC DỮ LIỆU & ỨNG DỤNG

Khai phá Tri thức từ Dữ liệu Vận hành POS với quy trình CRISP-DM và Học máy Không giám sát

Giảng viên hướng dẫn: TS. Nguyễn Tấn Trung

Nhóm sinh viên thực hiện:

49.01.104.030 - Trần Hoàng Đạt
50.01.104.090 - Võ Văn Minh
49.01.104.133 - Nguyễn Trần Bảo Thái

TP. Hồ Chí Minh, ngày 23 tháng 5 năm 2026

1. Phát biểu bài toán

Vấn đề: 236 ca làm việc trong gần 5 tháng, có sự két lệch liên tục, không có nhãn giám sát, vậy làm thế nào tự động phân loại rủi ro?

Nguồn	POS Apps Script — Cửa hàng thực tế, TP.HCM
MainLog	242 bản ghi chốt ca, có cột `actual_cash` (thủ quỹ tự đếm)
DetailsTransaction	5.412 giao dịch, có cột `notes` phi cấu trúc
Nhãn giám sát	Không có — hoàn toàn unsupervised
Thời gian thu thập	12/2025 — 04/2026 (5 tháng liên tục)
Điểm độc đáo	Số tiền kiểm két vật lý thực + ghi chú tay viết tắt tiếng Việt

Thách thức dữ liệu: Dữ liệu hoàn toàn không có nhãn và chứa nhiều trường thông tin phi cấu trúc (tiếng lóng, viết tắt). Buộc phải dùng các phương pháp Phân tích dữ liệu cơ bản và các thuật toán Học máy không giám sát.

Đầu vào: Hai tệp dữ liệu không nhãn.
Đầu ra mong muốn: Tạo ra báo cáo kiểm toán hoàn chỉnh và bộ dữ liệu được dán nhãn theo các quy luật.

=> Giải pháp đề xuất: Sử dụng quy trình CRISP-DM để khai thác bộ dữ liệu

2. Quy trình xử lý:

01. Business Understanding - Kỹ thuật chính:

Domain analysis, POS operation

02. Data Understanding - Kỹ thuật chính: EDA:

KDE, Scatter, Heatmap

03. Data Preparation - Kỹ thuật chính: merge_asof

04. Modeling Kỹ thuật chính: K-Means, DBSCAN,

Ward, IQR

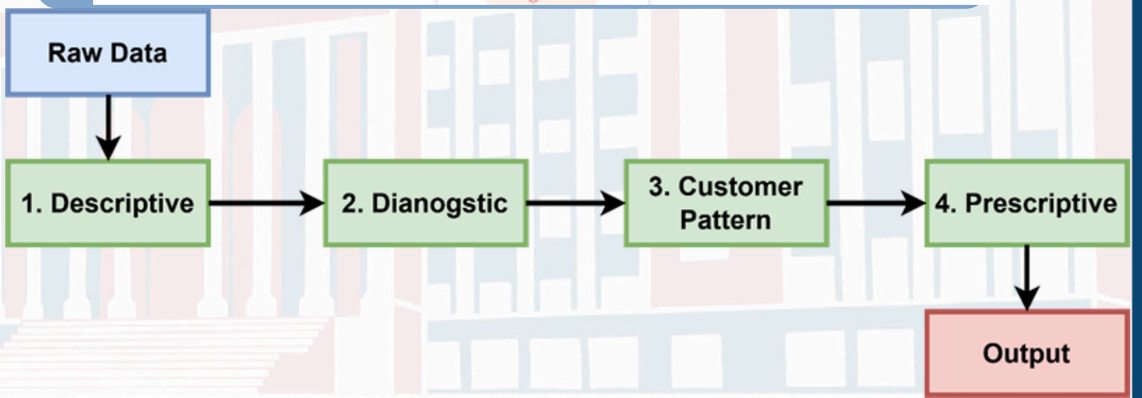
05. Evaluation Kỹ thuật chính: Silhouette, ARI,

Rule

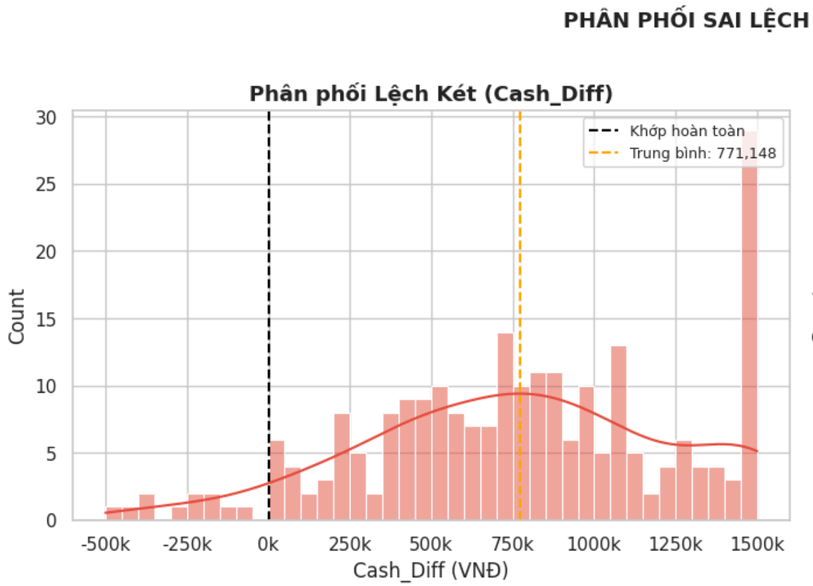
06. Engine Deployment Kỹ thuật chính: Report

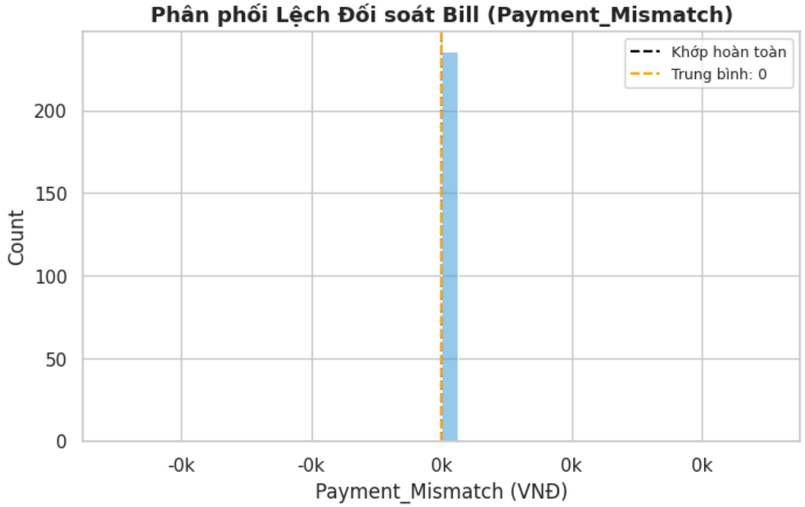
Generator, CSV output

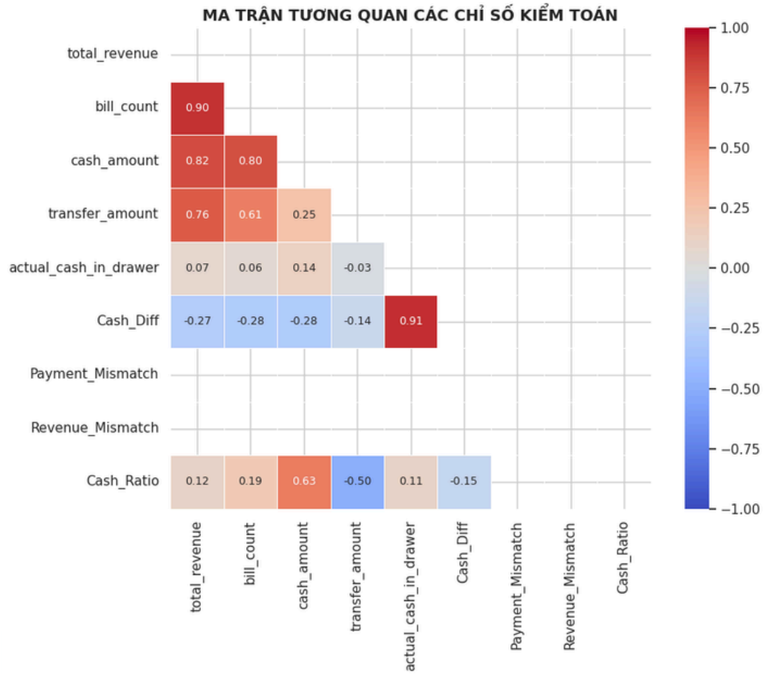


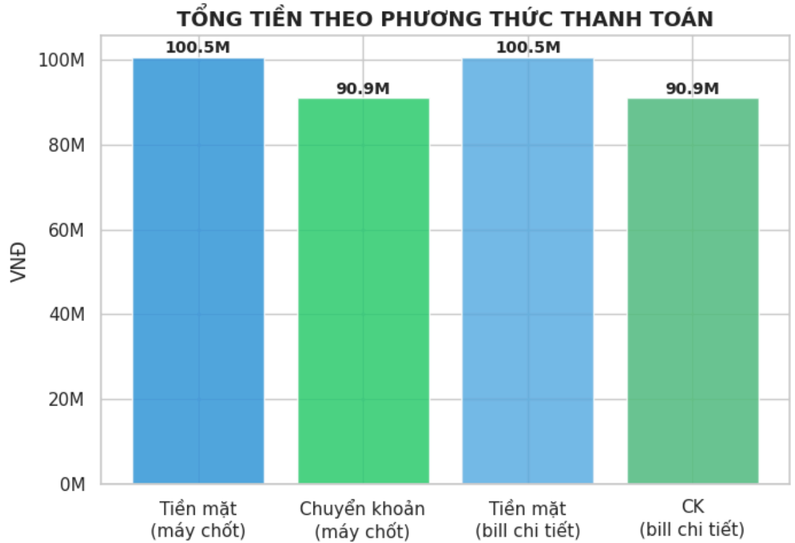


3. Vòng 1 & Vòng 2 - Hiểu nghiệp vụ & Bộ dữ liệu





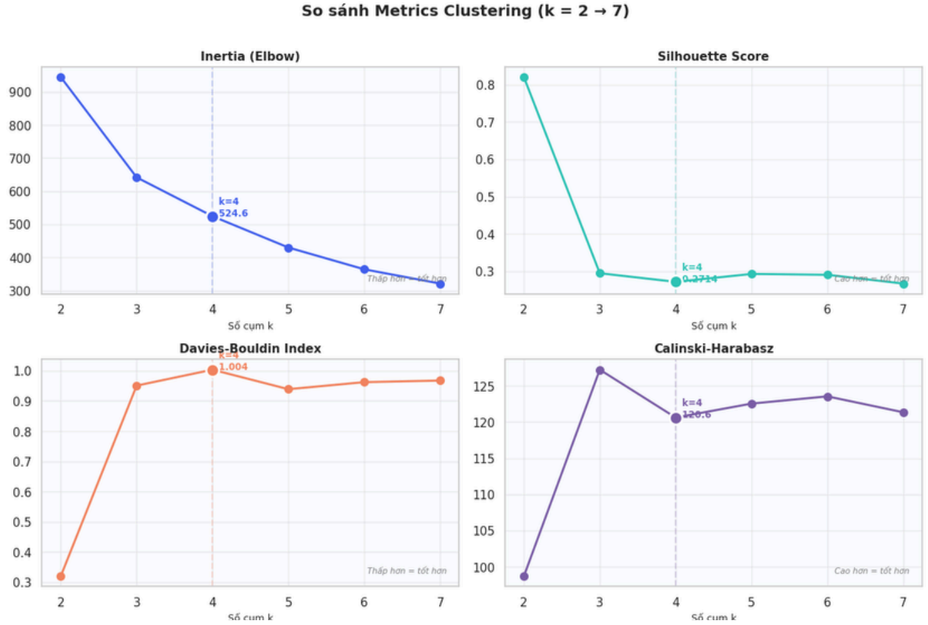




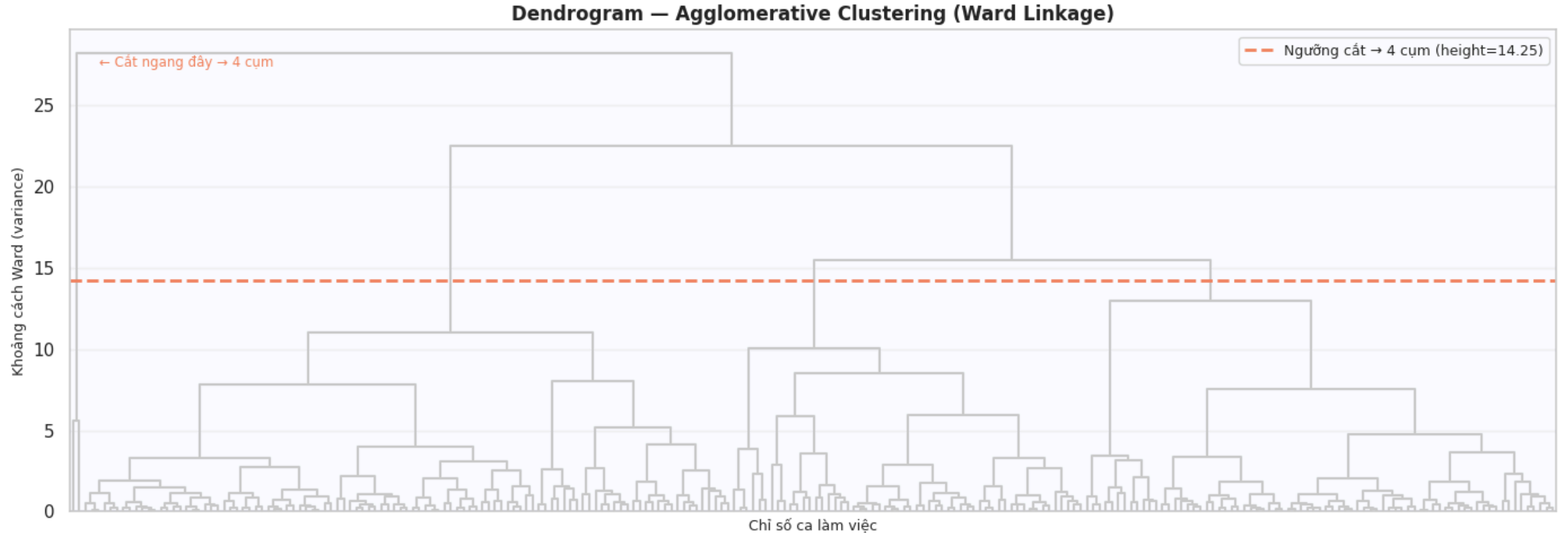


=> Output: Audit_Merged_Data.csv 236 ca đã làm sạch, "Single Source of Truth" cho toàn pipeline.
Mining 6 đặc trưng kiểm toán: Cash_Diff,Payment_Mismatch, Revenue_Mismatch,Cash_Ratio, CashDiff_Ratio, Shift_Velocity.

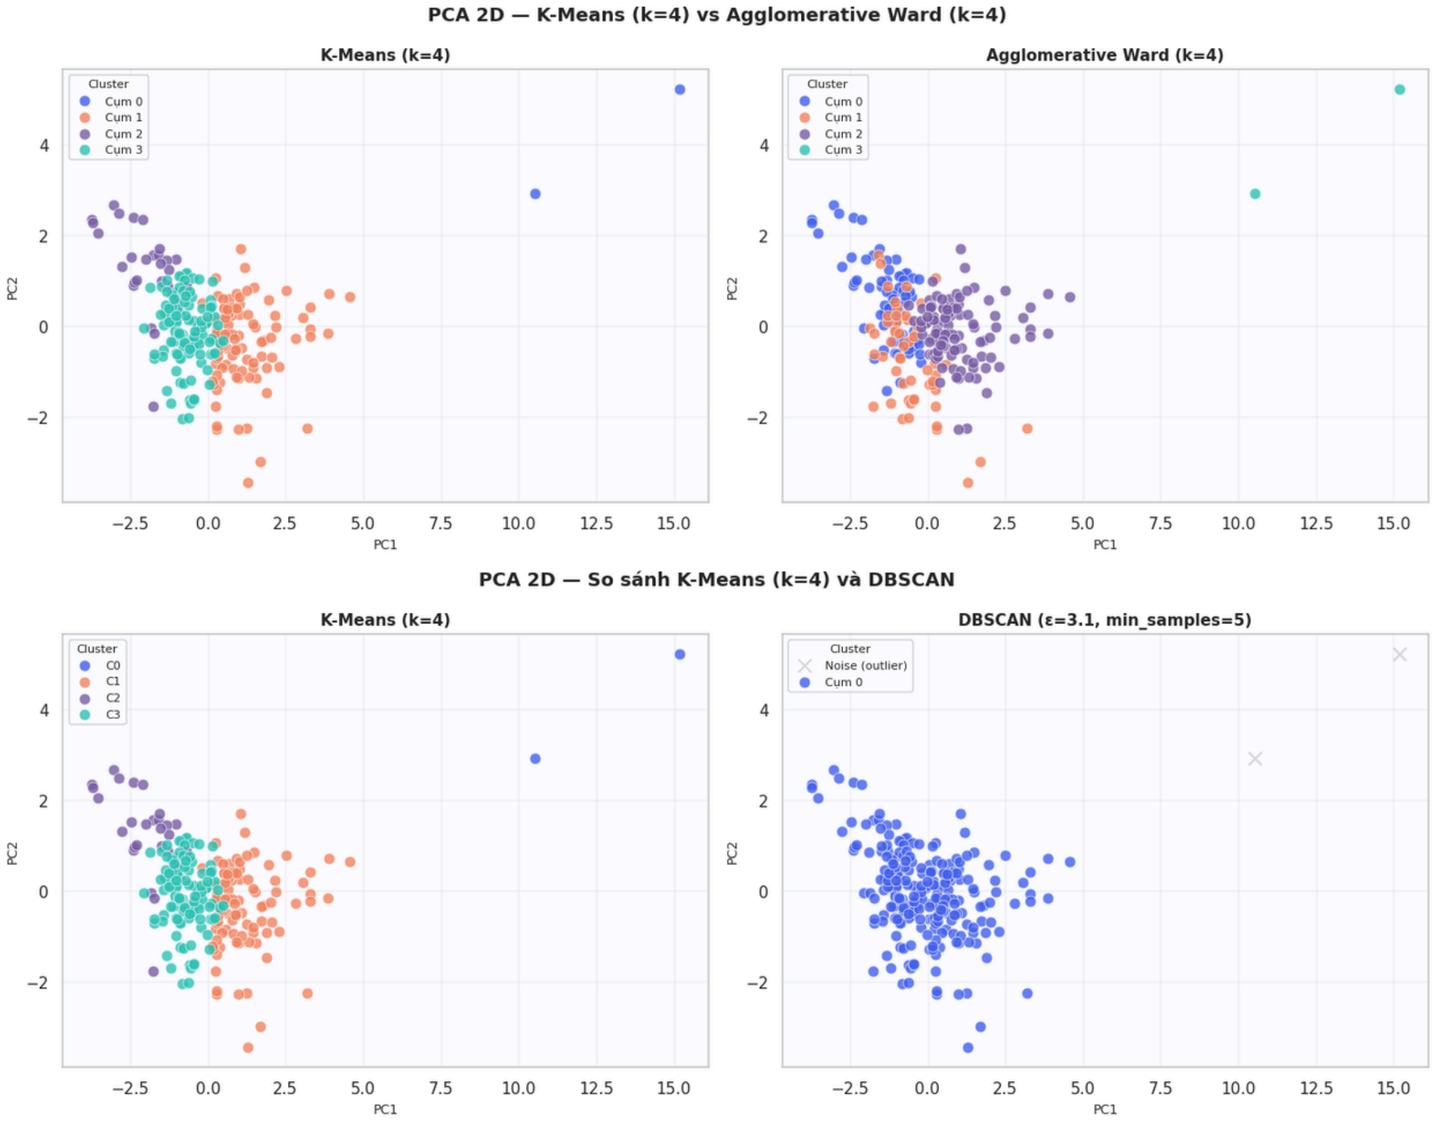
4. Đánh giá Metrics và Chọn k=4 tối ưu



=> Quyết định: k=4 được lựa chọn vì Elbow rõ ràng, 4 cụm có tên và hành vi nghiệp vụ phân biệt được, đồng thời được xác nhận bởi Dendrogram (Agglomerative Ward cũng cho thấy 4 nhánh tự nhiên).



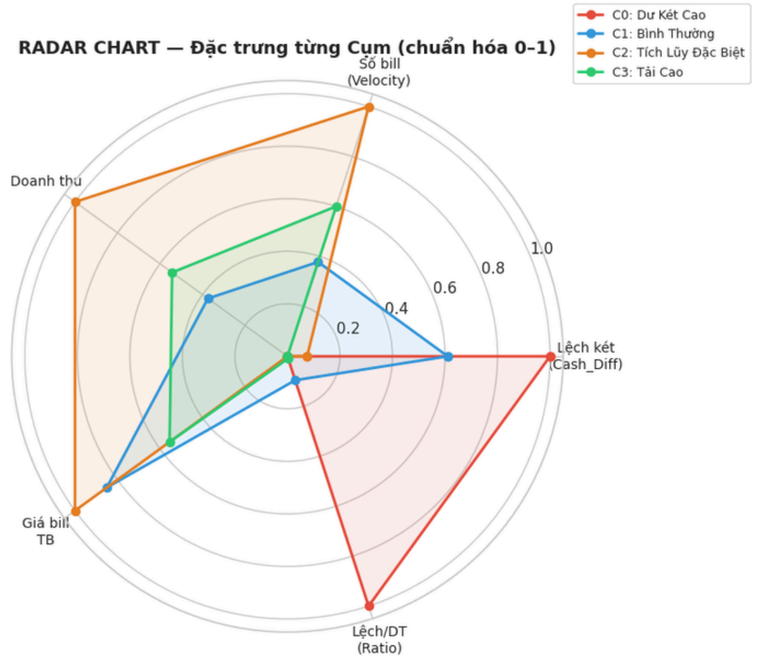
5. Kiểm chứng chéo các cụm với DBSCAN và Agglomerative Ward

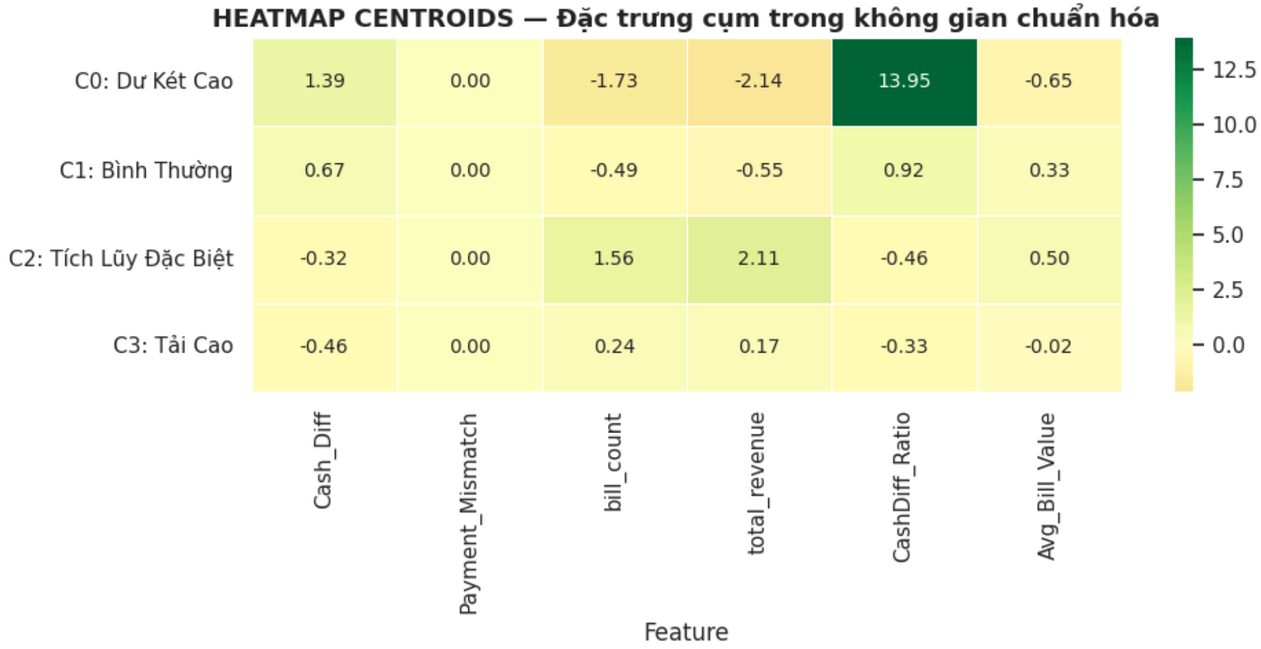


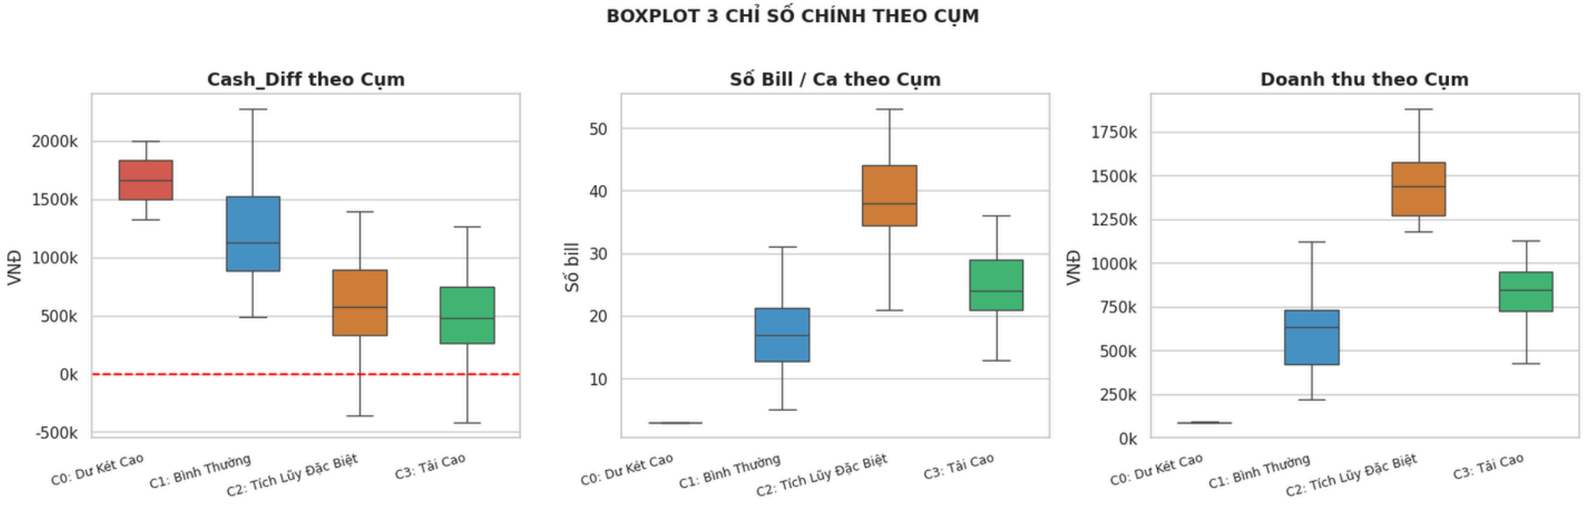
Mục đích: K-Means giả định cụm có dạng gần hình cầu và nhạy cảm với khởi tạo ban đầu. Vì vậy, hai thuật toán phân cụm độc lập được sử dụng để kiểm chứng tính ổn định của cấu trúc dữ liệu.

=> Kết luận: Ba thuật toán với ba cơ chế khác nhau đều xác nhận sự tồn tại của các nhóm ca làm việc có hành vi phân biệt, đặc biệt là 2 ca outlier C0 bị tất cả cùng đẩy ra ngoài.

6. Phân tích sự khác biệt của bốn cụm







Kết quả phân tích:

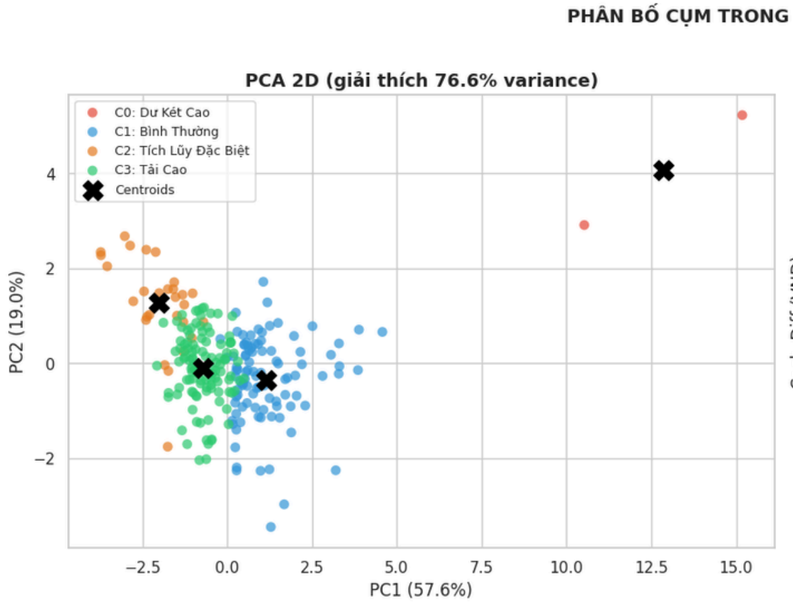
C0: Dư Két Cao (2 ca, Outlier)

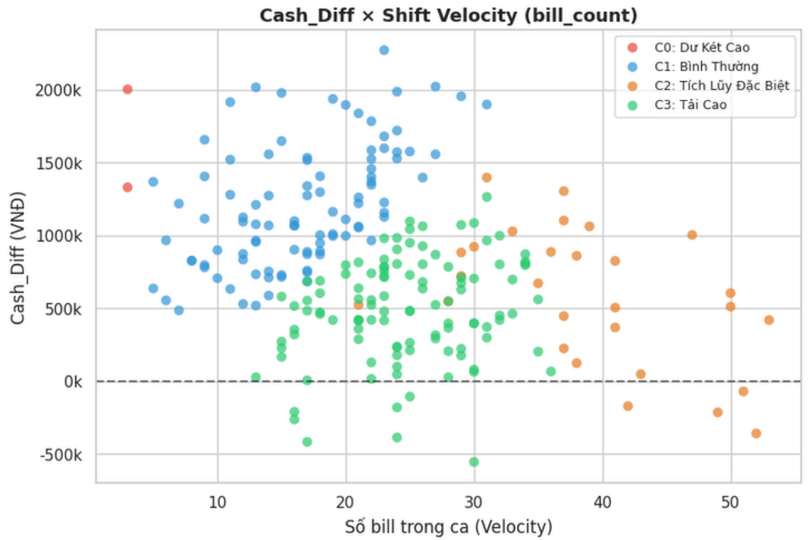
C1: Bình Thường (96 ca)

C2: Tích Lũy Đặc Biệt (28 ca)

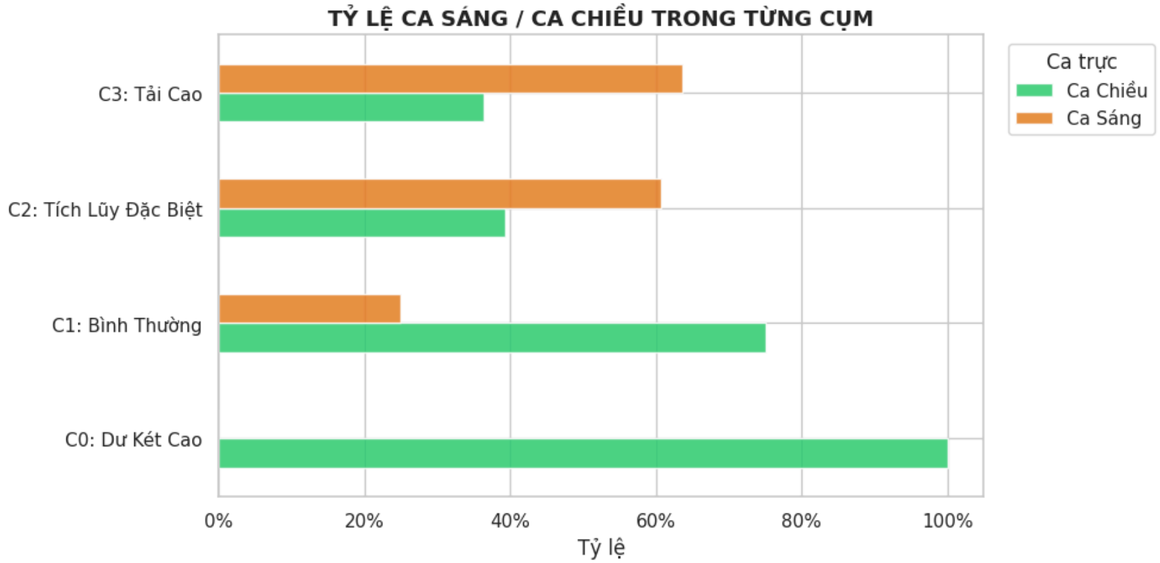
C3: Tải Cao (110 ca)

7. Phân tích không gian đa chiều (PCA) & Xu hướng theo Ca





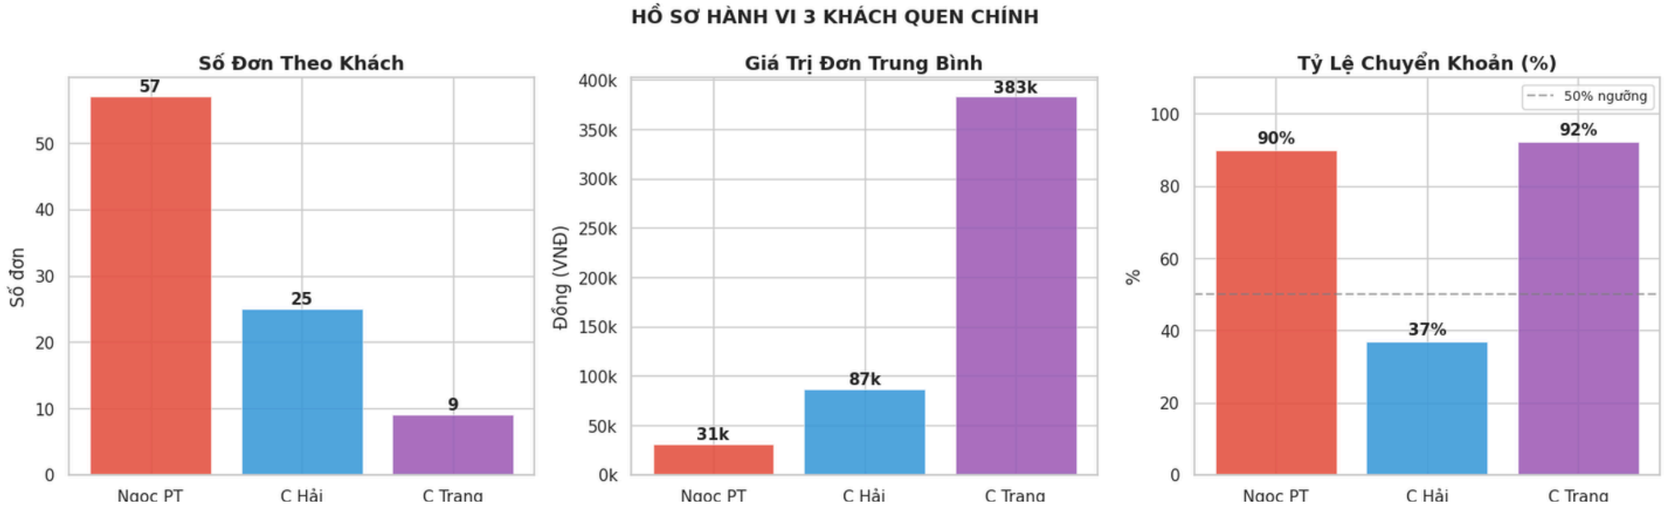


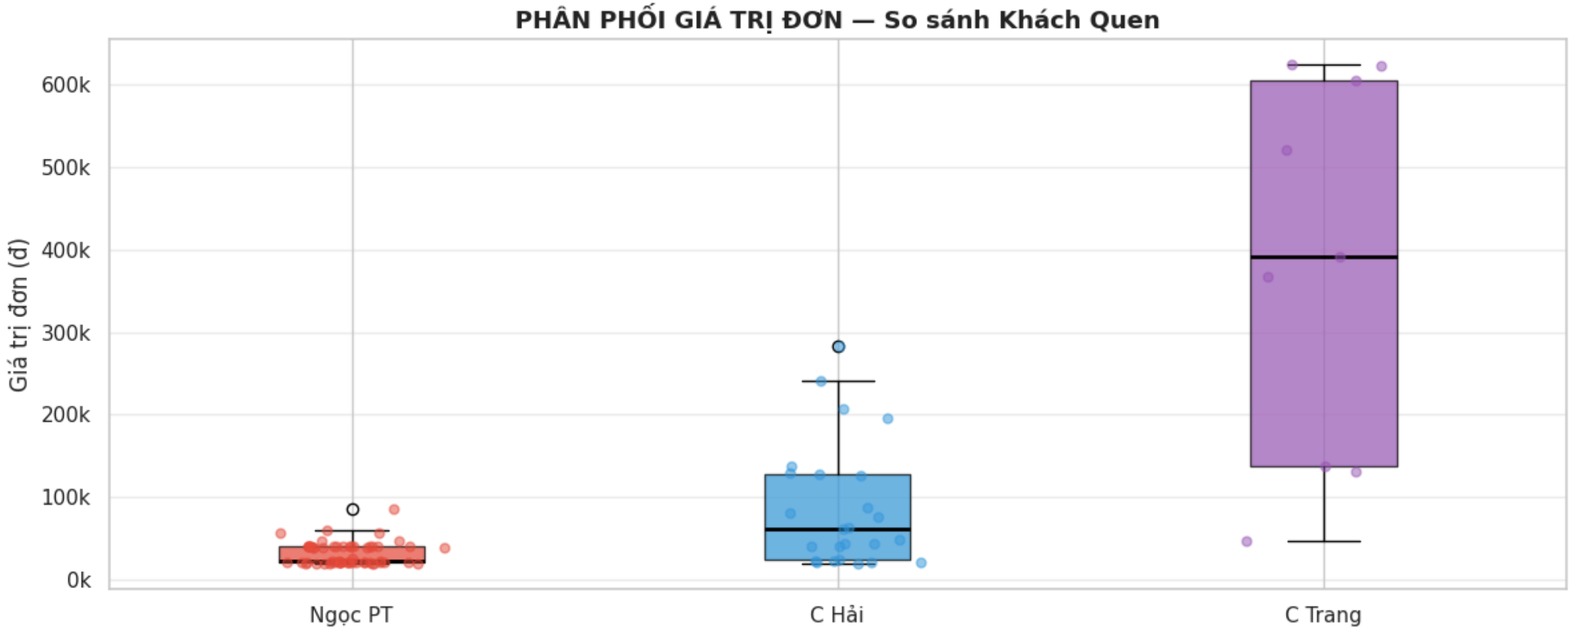


=> Không có tính mùa vụ: Scatter theo thời gian và stacked bar theo tháng đều cho thấy tỷ lệ các cụm ổn định qua 5 tháng. Rủi ro không tập trung vào giai đoạn nào — đây là đặc điểm hệ thống, không phải biến động thời vụ.

=> Output: Clustered_Shifts.csv, 236 ca làm việc được gán nhãn C0–C3, làm đầu vào cho Rule Engine và các bước phân tích rủi ro tiếp theo.

8. Phát hiện giao dịch dị biệt

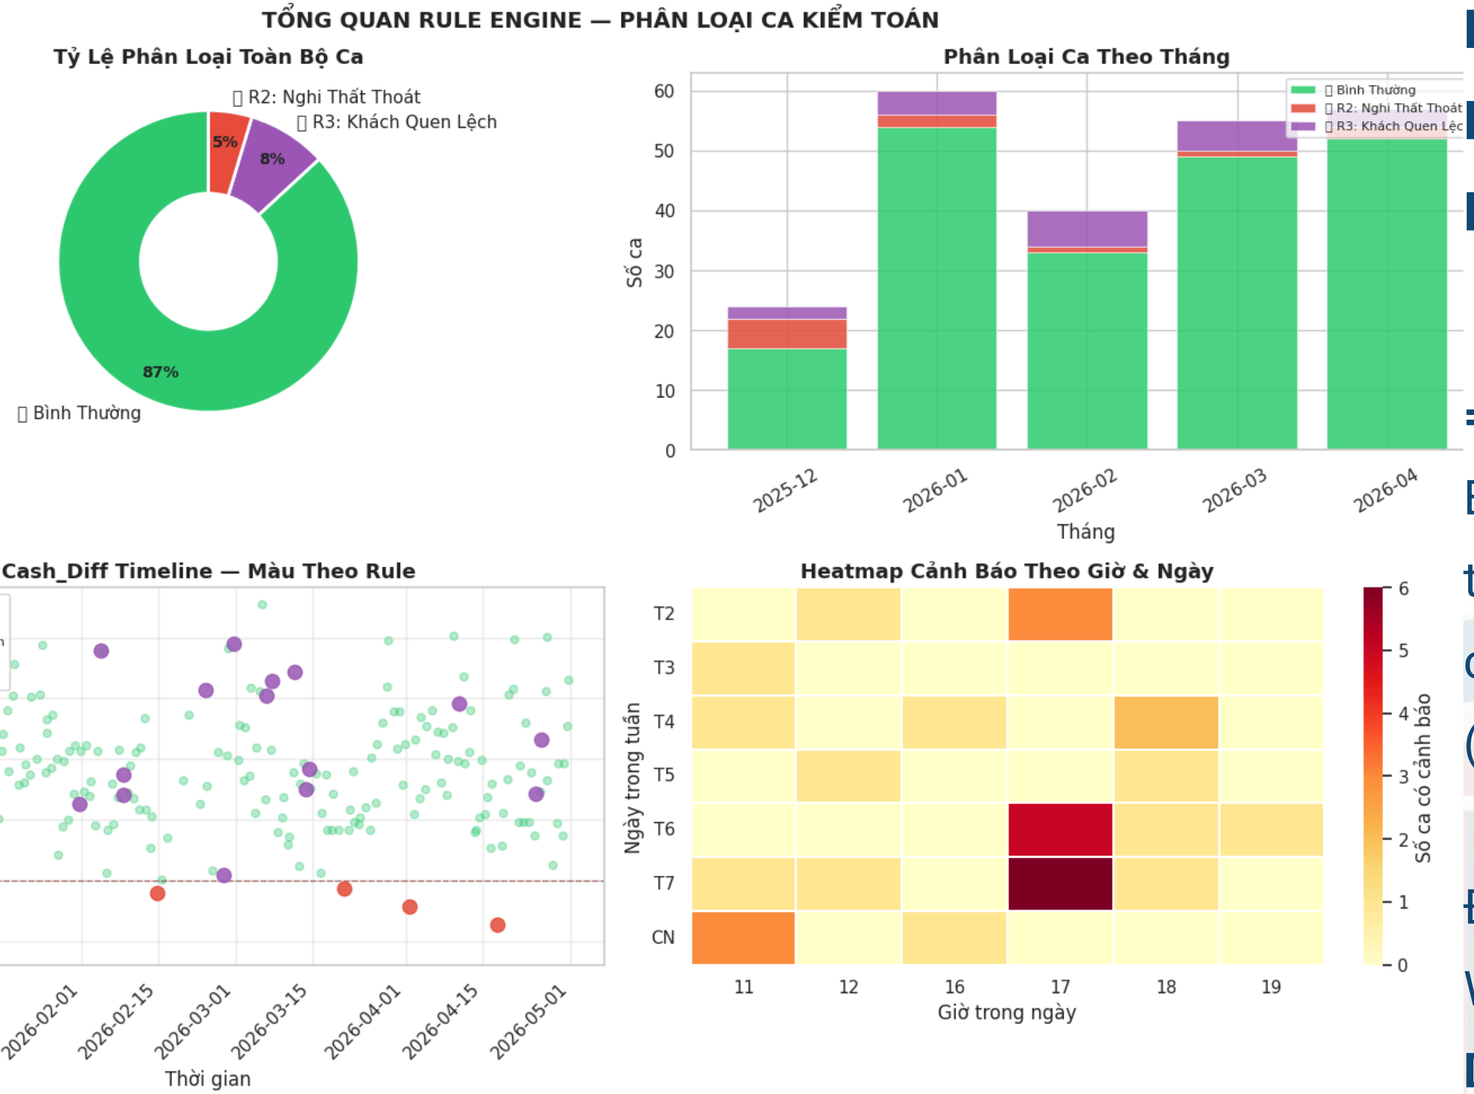




Vấn đề: Nhân viên gõ tên khách kiểu chat ("Ngọc pt", "n9oc pt", "c hải"...). LLM như PhoBERT không đọc được viết tắt này; 101 samples quá ít để fine-tune bất kỳ mô hình ngôn ngữ nào.

=> Output: Customer_Pattern.csv 101 hóa đơn đã chuẩn hóa, dán nhãn khách, gắn cờ cảnh báo bất thường.

9. Xây dựng hệ chuyên gia



Cơ chế hoạt động của Rule Engine

R1: Nhầm loại tiền

R2: Nghi thất thoát thu ngân

R3: Dư két bất thường

=> Output: POS_Master.csv — Bảng Master hoàn chỉnh hợp nhất toàn bộ pipeline 4 vòng. Chứa 36 cột đã chuẩn hóa chuyên sâu (categorical/int).

Đóng vai trò là nền tảng Data Warehouse cho vòng đời **CRISP-DM kế tiếp.**

10. Triển khai thực tế và tác động thực tiễn

Đóng góp chính:

- Dataset thực tế hiếm: có actual_cash + notes phi cấu trúc tiếng Việt — không tồn tại trên Kaggle
- Hybrid approach: ML khám phá pattern ẩn → Rule Engine thực thi minh bạch, giải thích được
- Zero-LLM deployment: đủ nhẹ để tích hợp vào POS nhỏ lẻ không có cloud

Hướng phát triển: Thêm Isolation Forest cho Vòng 2, fine-tune PhoBERT khi có thêm dữ liệu notes, alert real-time qua Telegram Bot

TRƯỜNG ĐẠI HỌC SƯ PHẠM THÀNH PHỐ HỒ CHÍ MINH
Ho Chi Minh City University of Education

Chất lượng - Sáng tạo - Nhân văn

XIN CẢM ƠN QUÝ THẦY CÔ VÀ CÁC BẠN SINH VIÊN ĐÃ LẮNG NGHE

