BỘ GIÁO DỤC VÀ ĐÀO TẠO
TRƯỜNG ĐẠI HỌC SƯ PHẠM TP.HCM
KHOA CÔNG NGHỆ THÔNG TIN



Xử lý ngôn ngữ tự nhiên

ĐỀ TÀI: Phân tích cảm xúc theo khía cạnh trên đánh giá nhà hàng

Giảng viên hướng dẫn: ThS. Trần Quang Huy
Sinh viên thực hiện:
49.01.104.069 – Ngô Quang Khánh
49.01.104.030 – Trần Hoàng Đạt
49.01.104.152 – Bùi Minh Tín
49.01.104.089 – Lý Tiểu Mẫn
49.01.104.094 – Nguyễn Đặng Đại Nam

TP. HỒ CHÍ MINH - 2026

PHÂN CÔNG CÔNG VIỆC

Thành viên	Nhiệm vụ phụ trách	Tỷ lệ đóng góp (%)
Khánh	Tổng hợp phương pháp CNN; xây dựng sườn slide; tiền xử lý dữ liệu; hoàn thành phần giới thiệu và công trình liên quan; huấn luyện mô hình trên Res16; vẽ kiến trúc mô hình; Viết Chương phương pháp đề xuất, kết quả thực nghiệm	**100%**
Tín	Tổng hợp và trực quan hóa bộ dữ liệu Twitter US Airline, IMDB và bộ dữ liệu có emoji; phân tích quy trình tiền xử lý cho AWARE và Res16; trực quan hóa dữ liệu; viết Chương 4.1 bộ dữ liệu Res16.	**100%**
Mẫn	Tổng hợp các phương pháp Hybrid cho Sentiment Analysis (2022–2026); mô tả bộ dữ liệu và thống kê dữ liệu; viết Chương 3.1 tiền xử lý Res16; tham gia Meet Test	**100%**
Đạt	Tổng hợp các công trình về biểu diễn từ vựng (CBOW, Skip-gram, FastText, TF-IDF, BoW); viết chi tiết mục 3.3 mô hình đề xuất; tham gia xây dựng mô hình đề xuất; thực hiện nghiên cứu loại trừ baseline	**100%**
Nam	Tổng hợp các phương pháp Transformer (BERT, RoBERTa,...); viết phần phương pháp đánh giá (Accuracy, Precision, Recall, F1-score); thực hiện nghiên cứu loại trừ cấu hình	**100%**

MỤC LỤC

DANH MỤC HÌNH ẢNH **5**

DANH MỤC BẢNG BIỂU **6**

CHƯƠNG 1. GIỚI THIỆU **7**

1.1. Phân tích cảm xúc theo khía cạnh là gì? **7**

1.2. Thách thức bài toán **7**

CHƯƠNG 2. CÔNG TRÌNH LIÊN QUAN **8**

2.1. Phương pháp xử lý mất cân bằng dữ liệu **8**

2.2. Mô hình CABiLSTM-BERT **8**

CHƯƠNG 3. PHƯƠNG PHÁP ĐỀ XUẤT **12**

3.1. Phương pháp tiền xử lý **12**

3.1.1. Phân tích trực quan và xác định vấn đề **12**

3.1.2. Đề xuất hướng xử lý **13**

3.1.3. Minh họa quá trình biến đổi qua từng bước xử lý **14**

3.2. Biểu diễn và mã hóa đầu vào **14**

3.3. Mô hình tổng quát **16**

CHƯƠNG 4. KẾT QUẢ THỰC NGHIỆM **19**

4.1. Bộ dữ liệu Res16 ..... **19**

4.1.1. Cấu trúc dữ liệu **19**

4.1.2. Thống kê dữ liệu **20**

4.1.3. Ví dụ minh họa cho 12 aspect. **22**

4.2. Phương pháp đánh giá **24**

4.2.1. Các độ đo cơ bản cho một lớp **25**

4.2.2. Tổng hợp bằng trung bình vĩ mô (Macro-average) **26**

4.2.3. Tổng hợp bằng trung bình trọng số (Weighted-average) 27
4.2.4. Ví dụ minh họa.....27
4.3. Kết quả trên bộ dữ liệu Res16 29
4.3.1. So sánh với các phương pháp SOTA 29
4.3.2. Nghiên cứu loại trừ.....30

DANH MỤC HÌNH ẢNH

Hình 2.1: Minh họa kỹ thuật trong SMOTE 8
Hình 2.2: Minh họa các bước trích xuất đặc trưng 10
Hình 3.1. Thống kê tỷ lệ các yếu tố gây nhiễu trong dữ liệu Res16 12
Hình 3.2. Mô hình đề xuất 16
Hình 4.1. Phân bố số lượng mẫu trong 12 aspect 24
Hình 4.2. Phân bố số lượng mẫu theo cảm xúc 24

DANH MỤC BẢNG BIỂU

Bảng 4.1. Cấu trúc tổ chức dữ liệu Res16 19
Bảng 4.2. Phân bố số lượng tập huấn luyện, đánh giá và kiểm thử.....20
Bảng 4.3. Phân bố Category trên tập Train.....20
Bảng 4.4. Phân bố Polarity trên tập Train.....21
Bảng 4.5. Phân bố Category trên tập Test (859 mẫu):.....21
Bảng 4.6. Phân bố Polarity trên tập Test 21
Bảng 4.7. Minh họa 12 aspect trong bộ dữ liệu Res16.....22
Bảng 4.8. Kết qủa so sánh với các phương pháp SOTA 30
Bảng 4.9. Nghiên cứu loại trừ với các mô hình ngôn ngữ.....31
Bảng 4.10. Nghiên cứu loại trừ với các cấu hình khác nhau 32

CHƯƠNG 1. GIỚI THIỆU

1.1. Phân tích cảm xúc theo khía cạnh là gì?

Aspect-Based Sentiment Analysis (ABSA) hay phân tích cảm xúc theo khía cạnh là một bài toán quan trọng trong lĩnh vực xử lý ngôn ngữ tự nhiên (NLP), nhằm mục tiêu xác định cảm xúc được biểu đạt đối với từng khía cạnh cụ thể trong một câu hoặc văn bản.

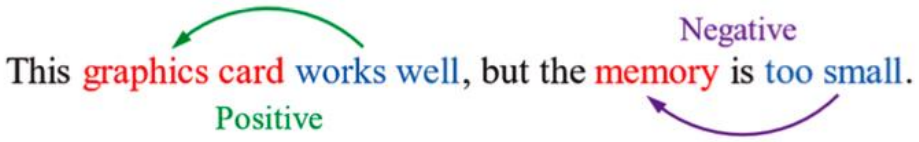
Khác với bài toán phân tích cảm xúc truyền thống (chỉ gán một nhãn cảm xúc chung cho toàn câu như tích cực, tiêu cực hoặc trung lập), ABSA đi sâu hơn bằng cách phân tích từng đối tượng hoặc khía cạnh (aspect) được nhắc đến trong câu.

Ví dụ, trong câu: "*Chất lượng camera rất tốt nhưng pin lại rất tệ*". Một mô hình phân tích cảm xúc tổng thể có thể kết luận là "trung lập" hoặc "hỗn hợp". Tuy nhiên, với ABSA, ta có thể xác định chính xác:

"*chất lượng camera*" → tích cực

"*pin*" → tiêu cực

Ví dụ khác:



1.2. Thách thức bài toán

Bài toán ABSA gặp nhiều khó khăn trong thực tế, bao gồm:

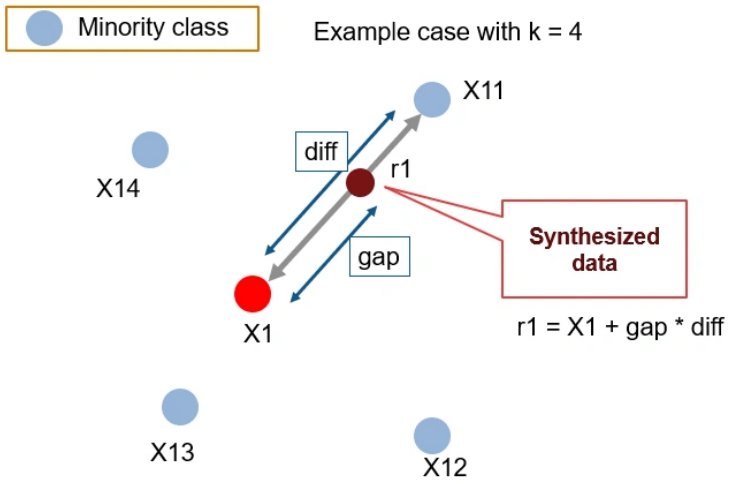
- Một câu có nhiều khía cạnh khác nhau với cảm xúc trái ngược nhau.
- Phụ thuộc ngữ cảnh: cảm xúc của một khía cạnh phụ thuộc mạnh vào các từ xung quanh.
- Khoảng cách xa giữa khía cạnh và từ cảm xúc trong câu dài.
- Câu có từ phủ định hoặc tương phản như "nhưng", "tuy nhiên" làm thay đổi hoàn toàn ý nghĩa.
- Cảm xúc ẩn (implicit sentiment), không được diễn đạt trực tiếp.

CHƯƠNG 2. CÔNG TRÌNH LIÊN QUAN

2.1. Phương pháp xử lý mất cân bằng dữ liệu

Để giải quyết tình trạng mất cân bằng dữ liệu (khi số lượng bài viết bình thường nhiều hơn đáng kể so với bài viết của người trầm cảm), nhóm nghiên cứu đã áp dụng kỹ thuật sinh mẫu thiểu số SMOTE (Synthetic Minority Oversampling Technique) trên các đặc trưng đầu ra. SMOTE hoạt động bằng cách chọn ngẫu nhiên một mẫu từ nhóm thiểu số và tạo ra một điểm dữ liệu mới nằm giữa mẫu đó và một trong các điểm lân cận gần nhất của nó. Cụ thể, theo công thức và hình bên dưới:

$$x_{new} = x_i + \lambda(x_j - x_i), \lambda \in (0,1)$$



Hình 2.1: Minh họa kỹ thuật trong SMOTE

Kỹ thuật này được áp dụng cho cả kết quả của Word-embeddings và Sentence Transformers để tạo ra quần thể dữ liệu huấn luyện cân bằng.

Tác giả đã thử sử dụng kỹ thuật sinh mẫu SMOTE (Synthetic Minority Over-sampling Technique) nhưng phát hiện ra rằng việc này không cải thiện hiệu suất, vì bản thân mô hình BERT đã có khả năng tổng quát hóa và xử lý rất tốt các vấn đề mất cân bằng dữ liệu.

2.2. Mô hình CABiLSTM-BERT

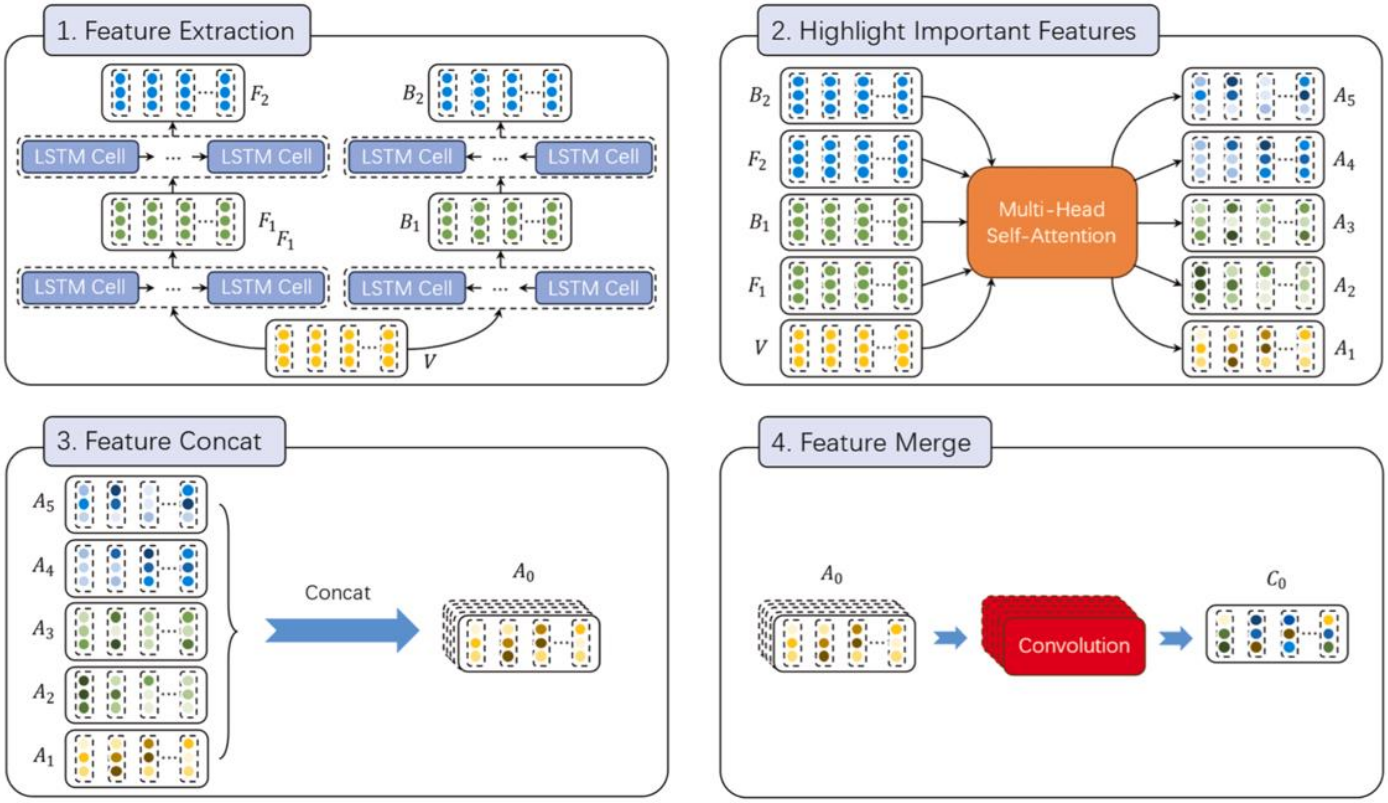
Điểm mới: kĩ thuật khai thác đặc trưng từ 2 lớp BiLSTM khác với phương pháp truyền thống. Áp dụng Multihead Self Attention nhằm khai thác làm nổi bật đặc trưng quan trọng. Áp dụng Convolution nhằm giữ các thông tin quan trọng (thông tin noise/yếu sẽ bị làm mờ đi).

Mô hình đề xuất bao gồm ba thành phần chính: (i) lớp biểu diễn đầu vào dựa trên BERT, (ii) lớp trích xuất đặc trưng tiềm ẩn sâu (Deep Implicit Feature Extraction Layer – CABiLSTM), và (iii) lớp phân loại cảm xúc.

Trước tiên, chuỗi đầu vào S′ (kết hợp giữa aspect và câu văn) cùng với các vector phân đoạn T và vị trí P được đưa vào BERT để sinh ra các vector biểu diễn ngữ cảnh $V = (v_1, v_2, \dots, v_L)$, trong đó mỗi vector v_i tương ứng với một token và đã chứa thông tin ngữ nghĩa phụ thuộc ngữ cảnh. Tiếp theo, các vector V được đưa vào lớp trích xuất đặc trưng tiềm ẩn sâu (CABiLSTM), đóng vai trò là thành phần cốt lõi của mô hình. Lớp này bao gồm ba mô-đun chính: BiLSTM hai tầng, cơ chế multi-head self-attention và lớp tích chập (CNN).

Đầu tiên, BiLSTM hai chiều hai tầng được sử dụng để khai thác các phụ thuộc dài hạn trong chuỗi văn bản theo cả hai hướng (trái → phải và phải → trái). Không giống các mô hình BiLSTM truyền thống chỉ sử dụng đầu ra của tầng cuối cùng (thông qua concate hai hướng), mô hình này giữ lại toàn bộ đầu ra của từng tầng và từng hướng, được minh họa tại bước 1hình 2-2. Theo tác giả, việc làm như vậy bởi vì: nếu chỉ dùng output cuối dẫn đến dễ mất thông tin từ các bước trước còn nếu giữ output từng layer thì mô hình có thêm "góc nhìn đa tầng".

Cụ thể, với hai tầng BiLSTM, đầu ra bao gồm chuỗi ban đầu V, cùng với các chuỗi ẩn theo từng hướng của mỗi tầng, được biểu diễn dưới dạng $\{V, F_1, B_1, F_2, B_2\}$, trong đó F_i và B_i lần lượt là chuỗi ẩn theo hướng xuôi và ngược của tầng thứ i. Cách tiếp cận này giúp giảm thiểu mất mát thông tin và giữ lại nhiều đặc trưng ngữ cảnh quan trọng ở các mức độ khác nhau.



Hình 2.2: Minh họa các bước trích xuất đặc trưng

Sau khi trích xuất đặc trưng từ BiLSTM hai tầng, mô hình sử dụng cơ chế multi-head self-attention (MSA) nhằm làm nổi bật các mối quan hệ quan trọng trong chuỗi và tăng khả năng biểu diễn ngữ cảnh, được minh họa tại bước 2 hình 22-. Cụ thể, mỗi nhóm đặc trưng đầu vào được biến đổi tuyến tính để tạo ra ba thành phần là Query, Key và Value. Sau đó, cơ chế attention được áp dụng để tính toán mức độ liên quan giữa các token trong toàn bộ chuỗi, từ đó gán trọng số cao hơn cho các đặc trưng quan trọng. Để tăng khả năng học biểu diễn, mô hình sử dụng cơ chế multi-head attention, trong đó nhiều "head" song song học các khía cạnh khác nhau của cùng một chuỗi đầu vào. Kết quả từ các head này được ghép lại để tạo thành biểu diễn đặc trưng tổng hợp, giúp mô hình nắm bắt đa dạng mối quan hệ trong dữ liệu.

Sau khi áp dụng attention cho từng nhóm đặc trưng {V, F_1, B_1, F_2, B_2}, mô hình thu được các biểu diễn tương ứng và tiến hành ghép nối theo chiều kênh để tạo thành một biểu diễn thống nhất, minh họa tại bước 3 hình 2-2. Biểu diễn này sau đó được đưa qua một lớp

convolution nhằm hợp nhất thông tin quan trọng và loại bỏ nhiễu, giúp tăng tính ổn định của đặc trưng, minh họa tại bước 4 hình 2-2.

Cuối cùng, để phục vụ bài toán phân loại cảm xúc, mô hình thực hiện gộp đặc trưng theo toàn bộ chiều chuỗi bằng phép trung bình, tạo ra một vector biểu diễn tổng quát của câu. Vector này được đưa vào mạng fully-connected nhiều tầng để thực hiện phân loại, và đầu ra được chuẩn hóa bằng softmax để dự đoán nhãn cảm xúc cuối cùng (tiêu cực, trung tính hoặc tích cực).

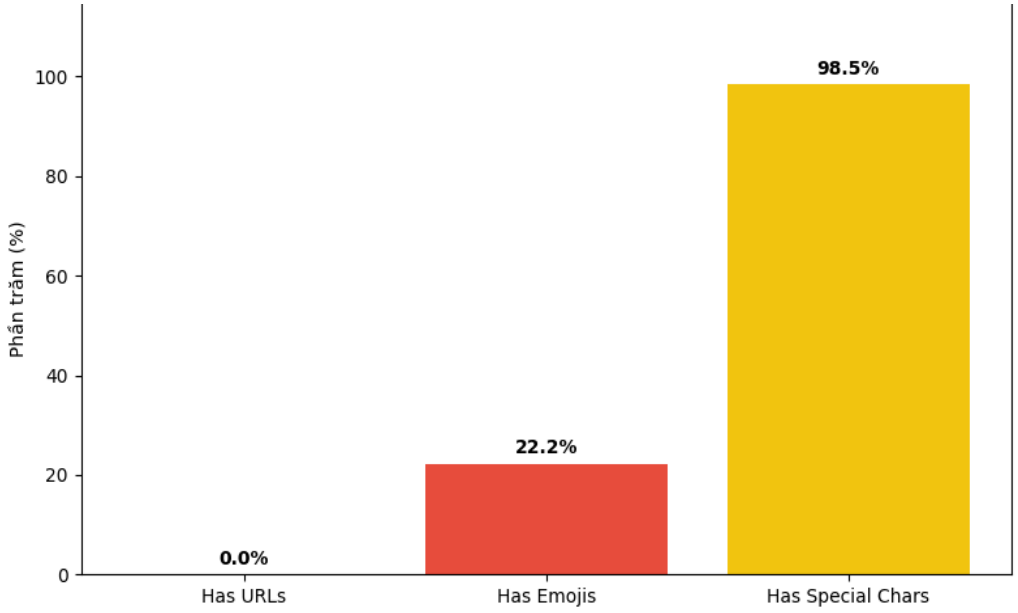
CHƯƠNG 3. PHƯƠNG PHÁP ĐỀ XUẤT

3.1. Phương pháp tiền xử lý

Quy trình tiền xử lý được thiết kế dựa trên việc phân tích trực quan các đặc thù của hai bộ dữ liệu Res16 (Restaurants) nhằm đưa văn bản về định dạng chuẩn cho mô hình Transformer.

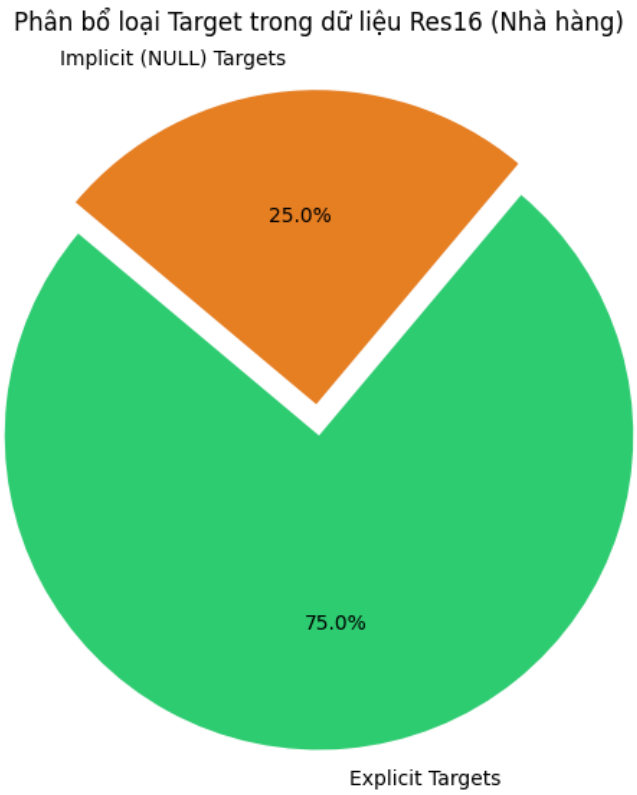
3.1.1. Phân tích trực quan và xác định vấn đề

Dựa trên các biểu đồ thống kê, nghiên cứu xác định các thách thức chính đối với từng bộ dữ liệu:



Hình 3.1. Thống kê tỷ lệ các yếu tố gây nhiễu trong dữ liệu Res16

Đối với bộ Res16, tỷ lệ câu chứa ký tự đặc biệt lên tới 98.5% và biểu tượng cảm xúc (Emoji) chiếm 22.2%, cho thấy nhu cầu cấp thiết của việc làm sạch nhiễu mạng xã hội.



Hình 3.2: Phân bổ các loại nhãn Target trong dữ liệu Res16

Đối với bộ Res16, khoảng 25% ý kiến là ngầm định (Implicit Targets), đòi hỏi quy trình xử lý nhãn chuyên biệt để mô hình có thể học được các khía cạnh không được chỉ định tường minh.

3.1.2. Đề xuất hướng xử lý

Dựa trên các phân tích trực quan, quy trình tiền xử lý được thiết lập bao gồm các bước sau:

Chuyển đổi chữ thường (Case conversion): Toàn bộ nội dung đánh giá được chuyển thành chữ in thường để đảm bảo tính đồng nhất, không phân biệt hoa/thường.

Xử lý biểu tượng cảm xúc (Removal of emojis): Các biểu tượng cảm xúc (emoji) được chuyển đổi thành các văn bản đại diện tương ứng.

Loại bỏ ký tự đặc biệt: Xóa bỏ các dấu câu, ký hiệu và khoảng trắng thừa không mang tính bảng chữ cái hay chữ số.

Phân tách văn bản (Tokenization of text): Chia nhỏ văn bản thành các đơn vị ngắn hơn (token) như từ, cụm từ hoặc ký tự.

Bổ đề hóa và Cắt gốc từ (Lemmatization & Stemming): Đưa các từ về nguyên dạng từ điển hoặc loại bỏ tiền tố/hậu tố để đưa từ về dạng cơ bản

3.1.3. Minh họa quá trình biến đổi qua từng bước xử lý

Sự biến đổi của một mẫu dữ liệu thô qua quy trình xử lý được minh họa chi tiết dưới đây:

Dữ liệu thô: *"Im an IT professional... realizd battery management was better!! 🤣 https://bit.ly/3xyz"*

Bước 1: Chuyển chữ thường: *"im an it professional... realizd battery management was better!! 🤣 https://bit.ly/3xyz"*

Bước 2: Loại bỏ URL: *"im an it professional... realizd battery management was better!! 🤣"*

Bước 3: Xử lý Emoji: *"im an it professional... realizd battery management was better!! [SMILE]"*

Bước 4: Loại bỏ ký tự đặc biệt: *"im an it professional realizd battery management was better"*

Bước 5: Phân tách văn bản: *"['im', 'an', 'it', 'professional', 'realizd', 'battery', 'management', 'was', 'better']"*

Bước 6: Bổ đề hóa: *"['i', 'be', 'an', 'it', 'professional', 'realize', 'battery', 'manage', 'be', 'better']"*

Thông qua quy trình tiền xử lý này, dữ liệu thô đã được tinh lọc và đưa về dạng đặc trưng bền vững, chuẩn bị cho các giai đoạn trích xuất đặc trưng tiếp theo của mô hình.

3.2. Biểu diễn và mã hóa đầu vào

Đầu vào của mô hình bao gồm ba thành phần chính: chuỗi từ S′, vector phân đoạn T và vector vị trí P. Trong đó, S′ là chuỗi đầu vào được xây dựng theo định dạng của BERT bằng cách kết hợp aspect và câu văn gốc, đồng thời bổ sung các token đặc biệt. Cụ thể, chuỗi này có dạng: [CLS] *aspect* [SEP *sentence*[SEP].

Ví dụ, với aspect *battery life* và câu *The battery life is good*, chuỗi đầu vào sẽ là: [CLS] battery life [SEP] the battery life is good [SEP].

Sau đó, chuỗi này được chuyển thành các chỉ số số nguyên (input IDs) dựa trên từ vựng đã được huấn luyện sẵn của BERT.

Bên cạnh đó, vector phân đoạn T được sử dụng để phân biệt các phần khác nhau trong chuỗi đầu vào. Cụ thể, các token thuộc phần aspect được gán giá trị 0, trong khi các token thuộc phần câu văn được gán giá trị 1. Với ví dụ trên, vector T tương ứng sẽ là [0,0,0,0,1,1,1,1,1,1]. Ngoài ra, vector vị trí P được xây dựng để biểu diễn vị trí của từng token trong chuỗi, nhằm cung cấp thông tin về thứ tự từ, với dạng [0,1,2,…].

Các thành phần này trước hết được chuyển sang dạng one-hot encoding thông qua hàm h(x), sau đó được ánh xạ sang không gian vector liên tục thông qua các ma trận trọng số học được. Cụ thể, biểu diễn embedding của từng thành phần được tính như sau:

- $E_S = W_s\, h(S')$: biểu diễn embedding của chuỗi từ
- $E_T = W_t\, h(T)$: biểu diễn embedding của phân đoạn
- $E_P = W_p\, h(P)$: biểu diễn embedding vị trí

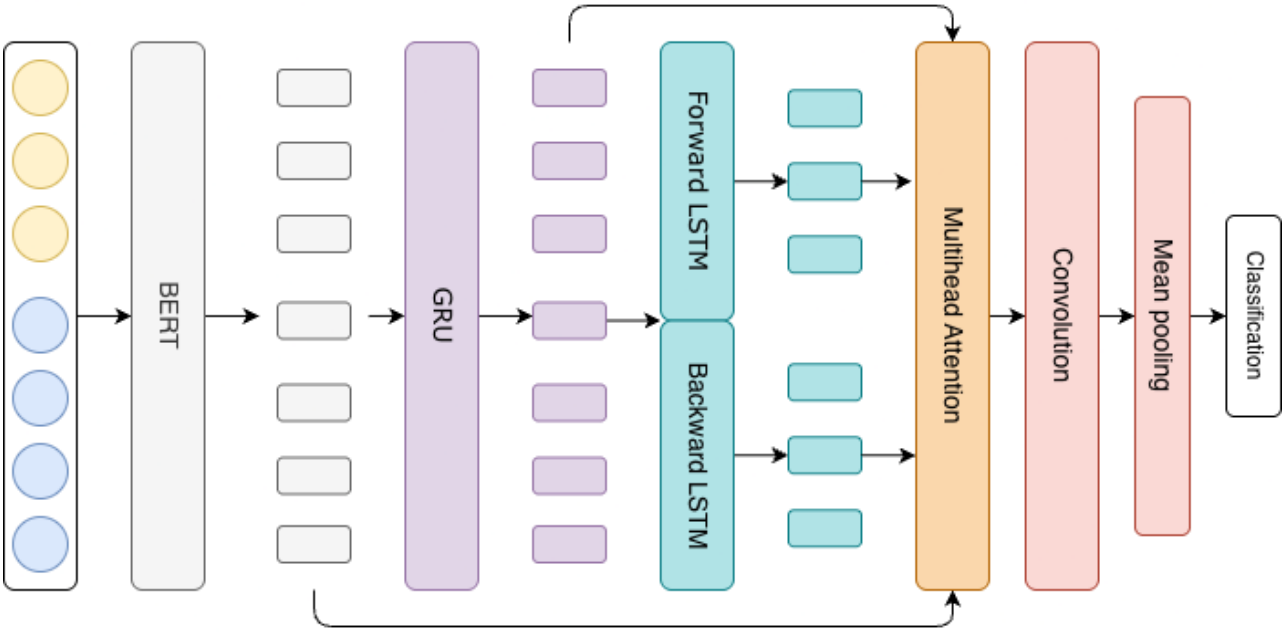
Trong đó, W_s, W_t, và W_p là các ma trận trọng số được huấn luyện.

Sau đó, ba thành phần embedding này được cộng lại để tạo thành biểu diễn đầu vào cuối cùng:

$$X = E_S + E_T + E_P$$

Vector X thu được sẽ được đưa vào mô hình BERT để thực hiện trích xuất đặc trưng ngữ cảnh. BERT bao gồm nhiều lớp Transformer encoder, mỗi lớp sử dụng cơ chế multi-head self-attention kết hợp với các lớp fully connected, cùng với residual connection và layer normalization nhằm học biểu diễn ngữ nghĩa sâu của chuỗi đầu vào.

3.3. Mô hình tổng quát



Hình 3.2. Mô hình đề xuất

Dựa trên nền tảng của mô hình CABiLSTM-BERT từ nghiên cứu của He et al. (2025), mô hình tổng quát được thiết kế nhằm mục đích tận dụng tối đa các đặc trưng ẩn (implicit features) ở nhiều tầng khác nhau để tránh việc mất mát thông tin ngữ nghĩa khi xử lý bài toán phân loại cảm xúc theo khía cạnh.

Về mặt phương pháp, kiến trúc này được điều chỉnh bằng cách sử dụng kết hợp giữa mạng GRU và BiLSTM để tăng cường khả năng trích xuất. Sự tinh chỉnh thứ tự các lớp (sử dụng GRU sau đó mới đến BiLSTM) xuất phát từ những đặc thù cốt lõi của dữ liệu trong bài toán ABSA: văn bản thường chứa nhiều thông tin nhiễu (irrelevant tokens), các từ mang tính quyết định cảm xúc thường nằm cách xa từ khía cạnh (long-distance dependency, ví

dụ: “not ... [SEP] ... good”), và thường xuyên xuất hiện các cảm xúc xung đột (conflict sentiment) trong cùng một ngữ cảnh.

Do đó, kiến trúc được thiết kế theo luồng xử lý tuần tự, với chi tiết đầu vào và đầu ra tại từng bước như sau (đối chiếu theo sơ đồ):

a. Lớp BERT:

Input: Chuỗi văn bản đầu vào (gồm từ khía cạnh và câu gốc) được mã hóa thành chuỗi các token có độ dài L (thể hiện qua các hình tròn trên cùng).

Output và Tác dụng: Đóng vai trò là bộ trích xuất ban đầu, chuyển đổi chuỗi token thành ma trận các vector nhúng (embeddings) mang ngữ cảnh sâu sắc V. Ma trận đầu ra này có kích thước *(L, 768)* (được biểu diễn bằng các ô vuông màu trắng).

b. Lớp GRU (Gated Recurrent Unit):

Input: Nhận toàn bộ ma trận V từ BERT.

Output và Tác dụng: Đóng vai trò như một bộ lọc thông tin cấp thấp. Nhờ cơ chế cổng cập nhật và cổng thiết lập lại, GRU giúp loại bỏ nhiễu và nén biểu diễn ngữ nghĩa. Đầu ra là chuỗi trạng thái ẩn H_{GRU} mang các pattern trọng yếu (được biểu diễn bằng các ô vuông màu tím).

c. Lớp BiLSTM (Bidirectional LSTM):

Input: Nhận chuỗi dữ liệu đã được tinh gọn H_{GRU}.

Output và Tác dụng: Giải quyết bài toán phụ thuộc dài bằng cách quét dữ liệu theo hai chiều. Đầu ra trả về hai chuỗi trạng thái ẩn riêng biệt: chiều quá khứ/xuôi ($H_{forward}$) và chiều tương lai/ngược ($H_{backward}$) được biểu diễn bằng các ô vuông màu xanh.

d. Multihead Attention & Concatenation:

Input: Để tận dụng tối đa "đặc trưng ẩn" (implicit features), đầu vào của lớp này bao gồm tất cả các đầu ra trước đó: V, H_{GRU}, $H_{forward}$, $H_{backward}$.

Output và Tác dụng: Tính toán cơ chế tự chú ý (Self-Attention) để làm nổi bật các đặc trưng quan trọng nhất có ảnh hưởng trực tiếp đến khía cạnh đang xét. Các ma trận đầu ra sau đó được nối gộp (concatenate) lại thành một ma trận đặc trưng khổng lồ, đảm bảo không bỏ sót bất kỳ thông tin ngữ nghĩa nào.

e. Convolution & Mean Pooling:

Input: Ma trận đặc trưng đã được nối gộp từ bước Attention.

Output và Tác dụng: Lớp Convolution 1D dung hợp (fusion) và đồng nhất biểu diễn. Tiếp theo, lớp Mean Pooling nhận ma trận 2D này và ép (hạ chiều) chuỗi L token thành một vector đặc trưng 1D duy nhất đại diện cho toàn bộ câu.

f. Lớp Classification:

Input: Vector 1D hoàn chỉnh từ Mean Pooling.

Output và Tác dụng: Đi qua mạng nơ-ron kết nối đầy đủ (Fully Connected Layer) và hàm Softmax để xuất ra vector phân bố xác suất cuối cùng, tương ứng với các nhãn cảm xúc (ví dụ: Tích cực, Tiêu cực, Trung lập).

Do đó, với kiến trúc đi từ Lọc nhiễu (GRU) đến Học ngữ cảnh sâu hai chiều (BiLSTM) và Tập trung chú ý (Attention), kết hợp với việc bảo toàn dòng chảy tensor ở mọi tầng, mô hình có khả năng phân biệt tương đối rõ ràng và chính xác các thái độ cảm xúc khác nhau đối với từng khía cạnh riêng biệt trong một câu phức tạp.

CHƯƠNG 4. KẾT QUẢ THỰC NGHIỆM

4.1. Bộ dữ liệu Res16

Bộ dữ liệu thuộc cuộc thi SemEval-2016 Task 5: Aspect-Based Sentiment Analysis, được cung cấp bởi tác giả fouadaurag20 trên Kaggle. Dữ liệu được lưu trữ dưới định dạng XML, bao gồm 4 file:

Bảng 4.1. Cấu trúc tổ chức dữ liệu Res16

File	Kích thước
restaurants_train_sb1.xml	~736 KB
restaurants_test_sb1.xml	~271 KB
Laptops_Train_sb1.xml	~821 KB
laptops_test_sb1.xml	~272 KB

Trong nghiên cứu này, chỉ sử dụng dữ liệu miền restaurant (nhà hàng).

4.1.1. Cấu trúc dữ liệu

Mỗi file XML chứa nhiều phần tử <Review>, bên trong mỗi review có nhiều <sentence>. Mỗi câu bao gồm:

<text>: Nội dung câu đánh giá (ví dụ: "The food was lousy - too sweet or too salty and the portions tiny.")

<Opinions>: Danh sách các opinion, mỗi opinion gồm:

target: Đối tượng được đánh giá (ví dụ: "food", "service") hoặc "NULL" nếu không có aspect cụ thể

category: Danh mục aspect theo định dạng ENTITY#ATTRIBUTE (ví dụ: FOOD#QUALITY, SERVICE#GENERAL)

polarity: Cảm xúc (positive, negative, neutral)

from, to: Vị trí ký tự của target trong câu

Lưu ý: Các câu không có nhãn opinion (không có thẻ <Opinions>) được loại bỏ trong quá trình parse dữ liệu.

4.1.2. Thống kê dữ liệu

Sau khi parse XML và trích xuất các cặp (sentence, category, polarity), dữ liệu thu được:

Bảng 4.2. Phân bố số lượng tập huấn luyện, đánh giá và kiểm thử

Tập	**Số mẫu**
Train	2.507
Test	859
Tổng	3.366

Phân bố Category trên tập Train (2.507 mẫu):

Bảng 4.3. Phân bố Category trên tập Train

Category	**Số lượng**
FOOD#QUALITY	849
SERVICE#GENERAL	449
RESTAURANT#GENERAL	422
AMBIENCE#GENERAL	255
FOOD#STYLE_OPTIONS	137
RESTAURANT#MISCELLANEOUS	98
FOOD#PRICES	90
RESTAURANT#PRICES	80
DRINKS#QUALITY	47
DRINKS#STYLE_OPTIONS	32
LOCATION#GENERAL	28
DRINKS#PRICES	20

Tổng cộng có 12 category khác nhau, trong đó FOOD#QUALITY chiếm tỷ lệ lớn nhất.

Phân bố Polarity trên tập Train (2.507 mẫu):

Bảng 4.4. Phân bố Polarity trên tập Train

Polarity	**Số lượng**
positive	1.657
negative	749
neutral	101

Phân bố Category trên tập Test (859 mẫu):

Bảng 4.5. Phân bố Category trên tập Test (859 mẫu):

Category	**Số lượng**
FOOD#QUALITY	313
SERVICE#GENERAL	155
RESTAURANT#GENERAL	142
AMBIENCE#GENERAL	66
FOOD#STYLE_OPTIONS	55
RESTAURANT#MISCELLANEOUS	33
FOOD#PRICES	23
DRINKS#QUALITY	22
RESTAURANT#PRICES	21
LOCATION#GENERAL	13
DRINKS#STYLE_OPTIONS	12
DRINKS#PRICES	4

Phân bố Polarity trên tập Test (859 mẫu):

Bảng 4.6. Phân bố Polarity trên tập Test

Polarity	**Số lượng**
positive	611
negative	204
neutral	44

4.1.3. Ví dụ minh họa cho 12 aspect.

Dựa trên kiến trúc tổng quát của mô hình đề xuất CABiLSTM, dữ liệu phân tích cảm xúc theo khía cạnh (ABSA) thực tế, đặc biệt là bộ dữ liệu SemEval-2016 (Restaurant), thường chứa các thách thức lớn như:

Phụ thuộc dài (Long-distance dependency): Từ mang tính quyết định cảm xúc nằm cách xa từ khía cạnh, dễ gây mất mát thông tin nếu không có cơ chế xử lý tốt.

Xung đột cảm xúc (Conflicting sentiment): Xuất hiện các cảm xúc trái ngược nhau đối với các khía cạnh khác nhau trong cùng một câu ngữ cảnh.

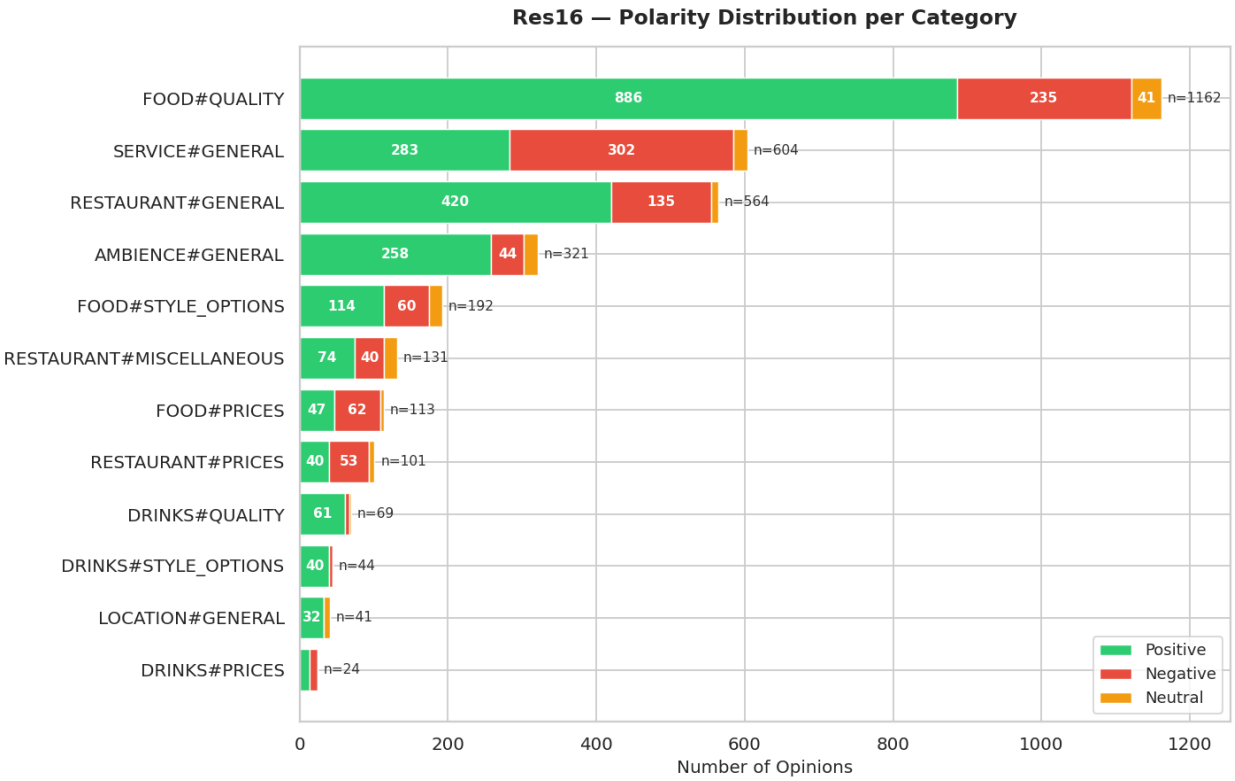
Ngữ nghĩa ẩn (Implicit features): Cảm xúc không được thể hiện qua các từ ngữ rõ ràng mà phải suy luận từ ngữ cảnh toàn cục của câu.

Kiến trúc CABiLSTM được thiết kế chuyên biệt để khắc phục các vấn đề này. Cụ thể, lớp GRU giúp lọc nhiễu chủ động và nén chuỗi token, lớp BiLSTM quét hai chiều để giải quyết sự phụ thuộc dài và duy trì trạng thái cảm xúc, và lớp Multi-head Attention giúp liên kết trực tiếp khía cạnh mục tiêu với các từ biểu đạt cảm xúc, kể cả khi chúng nằm xa nhau hoặc bị ẩn ý. Dưới đây là 12 ví dụ minh họa thực tế được trích xuất từ tập dữ liệu huấn luyện, đại diện cho 12 category aspect, thể hiện sự đa dạng và độ khó mà mô hình cần xử lý:

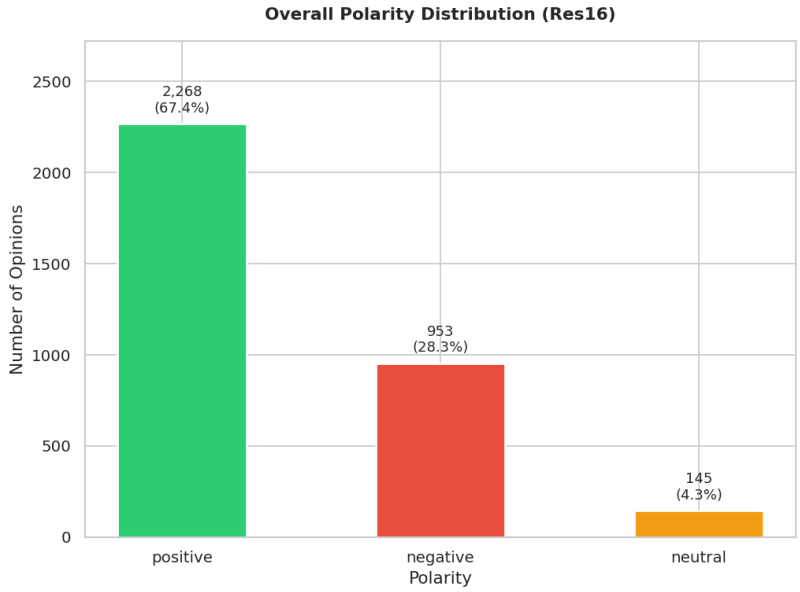
Bảng 4.7. Minh họa 12 aspect trong bộ dữ liệu Res16

ASPECT	**Aspect Target**	**Polarity**	**Câu đánh giá**
FOOD#QUALITY	food	negative	The food was lousy - too sweet or too salty and the portions tiny.
SERVICE#GENERAL	staff	negative	We, there were four of us, arrived at noon - the place was empty - and the staff acted

			like we were imposing on them and they were very rude.
RESTAURANT#GENERAL	place	negative	Judging from previous posts this used to be a good place, but not any longer.
AMBIENCE#GENERAL	decor	positive	Everything is always cooked to perfection, the service is excellent, the decor cool and understated.
FOOD#STYLE_OPTIONS	portions	negative	The food was lousy - too sweet or too salty and the portions tiny.
RESTAURANT#MISCELLANEOUS	crowd	positive	In the evening, this place attracted a well dressed, with it, NY crowd.
FOOD#PRICES	half price sushi deal	positive	We took advanatage of the half price sushi deal on saturday so it was well worth it.
RESTAURANT#PRICES	resturant	negative	Prices too high for this cramped and unappealing resturant.
DRINKS#QUALITY	wine	positive	We have been to this place many times, and always have great food, wine, and service.
DRINKS#STYLE_OPTIONS	wine list	positive	The wine list is interesting and has many good values.
LOCATION#GENERAL	view	positive	If you've ever been along the river in Weehawken you have an idea of the top of view the chart house has to offer.
DRINKS#PRICES	wine list	positive	The wine list is interesting and has many good values.



Hình 4.1. Phân bố số lượng mẫu trong 12 aspect



Hình 4.2. Phân bố số lượng mẫu theo cảm xúc

4.2. Phương pháp đánh giá

Để đánh giá hiệu năng của mô hình phân tích cảm xúc theo khía cạnh (ABSA), ta sử dụng các độ đo phổ biến cho bài toán phân loại đa lớp, bao gồm Precision, Recall và F1-score. Do bài toán có ba lớp cảm xúc (Tiêu cực, Trung tính, Tích cực) và phân bố dữ liệu thường không đồng đều (ví dụ số mẫu Trung tính thường nhiều hơn Tiêu cực và Tích cực), việc chỉ dùng độ chính xác tổng thể (Accuracy) có thể gây hiểu nhầm về khả năng thực sự của mô hình trên từng lớp. Vì vậy, bên cạnh việc tính các độ đo cho từng lớp riêng biệt, ta sử dụng hai cách tổng hợp kết quả: trung bình vĩ mô (macro-average) và trung bình trọng số (weighted-average).

4.2.1. Các độ đo cơ bản cho một lớp

Xét một lớp cảm xúc cụ thể $c \in \{\text{Negative,Neutral,Positive}\}$. Dựa trên ma trận nhầm lẫn (confusion matrix) giữa nhãn thực tế và nhãn dự đoán, ta xác định:

- **True Positive (TP_c)**: số mẫu thực sự thuộc lớp c và được mô hình dự đoán đúng là c.
- **False Positive (FP_c)**: số mẫu không thuộc lớp c nhưng bị dự đoán nhầm thành c.
- **False Negative (FN_c)**: số mẫu thực sự thuộc lớp c nhưng bị dự đoán nhầm sang lớp khác.

Từ các giá trị đó, ba độ đo cơ bản cho lớp c được định nghĩa như sau:

- **Precision (Độ chính xác)**:

$$\text{Precision}_c = \frac{TP_c}{TP_c + FP_c}$$

Precision cho biết trong tất cả các mẫu mà mô hình dự đoán là lớp c, tỉ lệ mẫu thực sự đúng là bao nhiêu. Chỉ số này cao đồng nghĩa với việc mô hình ít mắc lỗi nhầm lẫn (dự đoán là c nhưng thực tế không phải).

- **Recall (Độ bao phủ)**:

$$\text{Recall}_c = \frac{TP_c}{TP_c + FN_c}$$

Recall đo lường khả năng mô hình tìm ra được bao nhiêu phần trăm trong tổng số mẫu thực sự thuộc lớp ***c***. Recall cao cho thấy mô hình ít bỏ sót các mẫu của lớp đó.

- **F1-score (Điểm F1)**:

$$F1_c = 2 \times \frac{\text{Precision}_c \times \text{Recall}_c}{\text{Precision}_c + \text{Recall}_c}$$

F1-score là trung bình điều hòa của Precision và Recall. Giá trị này chỉ đạt mức cao khi cả Precision và Recall cùng cao, vì vậy nó phản ánh sự cân bằng giữa độ chính xác và độ bao phủ, đặc biệt hữu ích khi đánh giá mô hình trên các tập dữ liệu mất cân bằng.

4.2.2. Tổng hợp bằng trung bình vĩ mô (Macro-average)

Sau khi đã tính được Precision, Recall và F1 cho từng lớp trong số C lớp (ở đây $C = 3$), phương pháp trung bình vĩ mô (macro) tính trung bình cộng các giá trị này mà không quan tâm đến số lượng mẫu của mỗi lớp:

$$\text{Macro Precision} = \frac{1}{C}\sum_{c=1}^{C}\text{Precision}_c$$

$$\text{Macro Recall} = \frac{1}{C}\sum_{c=1}^{C}\text{Recall}_c$$

$$\text{Macro F1} = \frac{1}{C}\sum_{c=1}^{C}F1_c$$

Ý nghĩa: Macro-average coi mọi lớp có vai trò như nhau, không phân biệt lớp nhiều mẫu hay ít mẫu. Nhờ đó, nó rất nhạy cảm với hiệu năng trên các lớp thiểu số. Trong bài toán ABSA, nếu tập dữ liệu có rất ít đánh giá Tiêu cực, một mô hình chỉ giỏi dự đoán Trung tính và Tích cực sẽ có Macro Precision và Macro Recall thấp vì điểm số của lớp Tiêu cực kéo tổng thể xuống. Vì vậy, macro-average là thước đo nghiêm ngặt để đảm bảo mô hình hoạt động đồng đều trên tất cả các khía cạnh cảm xúc.

4.2.3. Tổng hợp bằng trung bình trọng số (Weighted-average)

Khác với macro, trung bình trọng số (weighted) gán cho mỗi lớp một trọng số tỉ lệ thuận với số mẫu thực tế của lớp đó trong tập dữ liệu. Gọi N_c là số mẫu thực tế của lớp c, tổng số mẫu $N = \sum_c N_c$. Trọng số $w_c = \frac{Nc}{N}$. Các chỉ số tổng hợp được tính như sau:

$$\text{Weighted Precision} = \sum_{c=1}^{C} w_c \cdot \text{Precision}_c = \sum_{c=1}^{C} \frac{N_c}{N} \cdot \text{Precision}_c$$

$$\text{Weighted Recall} = \sum_{c=1}^{C} w_c \cdot \text{Recall}_c$$

$$\text{Weighted F1} = \sum_{c=1}^{C} w_c \cdot F1_c$$

Ý nghĩa: Weighted-average phản ánh đúng ảnh hưởng của từng lớp đến hiệu năng tổng thể theo phân phối dữ liệu thực tế. Lớp nào chiếm tỉ lệ càng cao thì càng chi phối điểm trung bình. Điều này giúp ta trả lời câu hỏi: "Nếu triển khai mô hình trên thực tế (với phân phối giống tập kiểm tra), thì trung bình mô hình sẽ cho ra một dự đoán chính xác đến mức nào?". Weighted-average thường được dùng làm chỉ số chính khi tập dữ liệu mất cân bằng nghiêm trọng vì nó cho cái nhìn thực tế hơn, không bị ảnh hưởng quá mức bởi các lớp quá nhỏ có điểm cực cao hoặc cực thấp.

4.2.4. Ví dụ minh họa

Giả sử chúng ta có một tập kiểm tra gồm 100 câu đã gán nhãn khía cạnh và cảm xúc, phân bố thực tế như sau: Negative (Tiêu cực) 20 câu, Neutral (Trung tính) 70 câu, Positive (Tích cực) 10 câu. Sau khi chạy mô hình, ta thu được ma trận nhầm lẫn (confusion matrix):

Thực tế \ Dự đoán	Negative	Neutral	Positive
Negative	15	4	1
Neutral	3	62	5
Positive	0	3	7

Tính toán cho từng lớp:

- **Lớp Negative:**
  - $TP_{Neg} = 15$
  - $FP_{Neg} = 3 + 0 = 3$ (dự đoán Negative nhưng thực tế là Neutral hoặc Positive)
  - $FN_{Neg} = 4 + 1 = 5$ (Negative thực tế nhưng bị dự đoán sai)
  - $Precision_{Neg} = \frac{15}{15+3} \approx 0.833$
  - $Recall_{Neg} = \frac{15}{15+5} = 0.75$
  - $F1_{Neg} = 2 \times \frac{0.833 \times 0.75}{0.833+0.75} \approx 0.789$
- **Lớp Neutral:**
  - $TP_{Neu} = 62$
  - $FP_{Neu} = 4 + 3 = 7$
  - $FN_{Neg} = 3 + 5 = 8$
  - $Precision_{Neu} = \frac{62}{62+7} \approx 0.899$
  - $Recall_{Neu} = \frac{62}{62+8} \approx 0.886$
  - $F1_{Neu} = 2 \times \frac{0.899 \times 0.886}{0.899+0.886} \approx 0.892$
- **Lớp Positive:**
  - $TP_{Pos} = 7$
  - $FP_{Pos} = 1 + 5 = 6$
  - $FN_{Pos} = 0 + 3 = 3$
  - $Precision_{Pos} = \frac{7}{7+6} \approx 0.538$
  - $Recall_{Pos} = \frac{7}{7+3} = 0.7$
  - $F1_{Pos} = 2 \times \frac{0.538 \times 0.7}{0.538+0.7} \approx 0.609$
- **Tổng hợp Macro-average:**
  - Macro Precision $= \frac{0.833+0.899+0.538}{3} \approx 0.757$

- Macro Recall = $\frac{0.75+0.886+0.7}{3} \approx 0.779$
- Macro F1 = $\frac{0.789+0.892+0.609}{3} \approx 0.763$

- Tổng hợp Weighted-average (trọng số theo số mẫu thực tế):
  - $w_{Neg} = \frac{20}{100} = 0.2$
  - $w_{Neu} = \frac{70}{100} = 0.7$
  - $w_{Pos} = \frac{10}{100} = 0.1$
  - Weighted Precision = 0.2 x 0.833 + 0.7 x 0.899 + 0.1 x 0.538 ≈ 0.85
  - Weighted Recall = 0.2 x 0.75 + 0.7 x 0.886 + 0.1 x 0.7 ≈ 0.84
  - Weighted F1 = 0.2 x 0.789 + 0.7 x 0.892 + 0.1 x 0.609 ≈ 0.843

Nhận xét: Weighted F1 (0.843) cao hơn Macro F1 (0.763). Điều này xảy ra vì lớp Neutral chiếm đa số mẫu (70%) và có F1-score cao (0.892), kéo điểm trung bình trọng số lên. Trong khi đó, Macro F1 bị ảnh hưởng đáng kể bởi lớp Positive có F1-score thấp (0.609) dù lớp này chỉ có 10 mẫu. Sự khác biệt này đã minh họa rõ nếu chúng ta chỉ dùng một loại trung bình, có thể bỏ sót những điểm yếu của mô hình trên các lớp thiểu số hoặc ngược lại, đánh giá quá khắt khe khi lớp nhỏ có nhiễu. Do đó, việc báo cáo đồng thời cả hai chỉ số là cần thiết để có cái nhìn toàn diện.

4.3. Kết quả trên bộ dữ liệu Res16

4.3.1. So sánh với các phương pháp SOTA

Bảng 4.8 trình bày kết quả so sánh mô hình đề xuất với một số phương pháp tiên tiến trên bộ dữ liệu Res16. Kết quả cho thấy mô hình đề xuất đạt độ chính xác (Accuracy) 86.61%, tương đương với phương pháp CABiLSTM-BERT và cao hơn đáng kể so với các mô hình ATAE-LSTM (83.77%), BERT-base (82.11%) và UIKA-BERT (85.64%). Điều này cho

thấy mô hình có khả năng dự đoán chính xác nhãn cảm xúc ở mức độ cạnh tranh với các phương pháp hiện đại.

Tuy nhiên, xét trên chỉ số F1-score Macro, mô hình đề xuất đạt 59.67%, thấp hơn so với các mô hình UIKA-BERT (72.37%) và CABiLSTM-BERT (73.54%), đồng thời chỉ nhỉnh hơn BERT-base (56.43%). Kết quả này cho thấy mặc dù mô hình duy trì được độ chính xác tổng thể cao, khả năng cân bằng hiệu suất giữa các lớp cảm xúc vẫn còn hạn chế, đặc biệt trong trường hợp dữ liệu có sự mất cân bằng giữa các nhãn. Điều này cho thấy vẫn còn tiềm năng cải thiện cơ chế học biểu diễn hoặc chiến lược xử lý mất cân bằng dữ liệu để nâng cao hiệu quả phân loại trên các lớp thiểu số.

Bảng 4.8. Kết quả so sánh với các phương pháp SOTA

Method	**Accuracy**	**F1-score (Macro)**
ATAE-LSTM	83.77	61.71
ASGCN-DG	87.28	63.38
BERT(base)	82.11	56.43
UIKA-BERT	85.64	72.37
CABiLSTM-BERT	86.61	73.54
Mô hình đè xuất	86.61	59.67

4.3.2. Nghiên cứu loại trừ

Để đánh giá hiệu quả của các thành phần trong mô hình, nghiên cứu tiến hành hai thí nghiệm loại trừ (ablation study).

So sánh các mô hình ngôn ngữ nền tảng:

Kết quả ở Bảng 4.9 cho thấy việc thay đổi mô hình ngôn ngữ nền tảng ảnh hưởng đáng kể đến hiệu năng phân loại. Cụ thể, DeBERTa-base đạt kết quả tốt nhất với Accuracy 88.24% và F1-score Macro 61.41%. Trong khi đó, mô hình đề xuất sử dụng BERT-base đạt Accuracy 86.61% và F1-score Macro 59.67%, cao hơn nhẹ so với RoBERTa-base về

Accuracy nhưng thấp hơn một chút về khả năng phân loại cân bằng các lớp. Điều này cho thấy chất lượng biểu diễn ngữ nghĩa của mô hình ngôn ngữ nền tảng đóng vai trò quan trọng đối với bài toán Aspect-Based Sentiment Analysis.

Bảng 4.9. Nghiên cứu loại trừ với các mô hình ngôn ngữ

Baseline	**Accuracy**	**F1-score (Macro)**
RoBERTa-base	86.26	56.76
DeBERTa-base	**88.24**	**61.41**
BERT-base (Mô hình đề xuất)	86.61	59.67

Bảng 4.10 trình bày kết quả nghiên cứu loại trừ nhằm đánh giá mức độ đóng góp của từng thành phần trong kiến trúc đề xuất. Kết quả cho thấy mô hình đầy đủ đạt Accuracy 86.61% và F1-score Macro 59.67%, là cấu hình có độ chính xác cao nhất trong các thí nghiệm.

Khi loại bỏ GRU (w/o GRU), Accuracy giảm từ 86.61% xuống 86.03%, trong khi F1-score Macro giảm nhẹ từ 59.67% xuống 59.39%. Tương tự, khi loại bỏ BiLSTM (w/o BiLSTM), Accuracy cũng giảm xuống 86.03% và F1-score Macro giảm xuống 59.16%. Điều này cho thấy cả GRU và BiLSTM đều đóng vai trò quan trọng trong việc khai thác thông tin ngữ cảnh tuần tự, giúp mô hình học được các mối quan hệ phụ thuộc giữa các từ trong câu. Trong đó, BiLSTM có ảnh hưởng lớn hơn một chút đến khả năng phân loại cân bằng giữa các lớp khi việc loại bỏ thành phần này làm F1-score Macro suy giảm nhiều hơn so với trường hợp loại bỏ GRU.

Đối với cấu hình loại bỏ CNN (w/o CNN), Accuracy giảm đáng kể xuống còn 85.68%, thấp nhất trong tất cả các cấu hình khảo sát. Kết quả này cho thấy CNN đóng vai trò quan trọng trong việc trích xuất các đặc trưng cục bộ và các mẫu ngữ nghĩa quan trọng từ văn bản. Tuy nhiên, F1-score Macro của cấu hình này đạt 61.02%, cao hơn mô hình đầy đủ. Điều này cho thấy việc loại bỏ CNN giúp mô hình đạt hiệu suất cân bằng hơn trên các lớp dữ liệu, mặc dù làm giảm độ chính xác tổng thể. Sự khác biệt giữa Accuracy và F1-score

Macro phản ánh rằng CNN có xu hướng tối ưu hiệu quả dự đoán trên các lớp chiếm ưu thế trong tập dữ liệu.

Nhìn chung, kết quả nghiên cứu loại trừ cho thấy cả CNN, BiLSTM và GRU đều đóng góp tích cực vào hiệu năng của mô hình. Trong đó, CNN có ảnh hưởng lớn nhất đến độ chính xác tổng thể, trong khi BiLSTM và GRU hỗ trợ mô hình học các đặc trưng ngữ cảnh và duy trì hiệu suất ổn định giữa các lớp. Việc kết hợp đồng thời ba thành phần này giúp mô hình đạt được kết quả tốt nhất về Accuracy, chứng minh tính hiệu quả của kiến trúc đề xuất.

Bảng 4.10. Nghiên cứu loại trừ với các cấu hình khác nhau

Configuration	**Accuracy**	**F1-score (Macro)**
w/o GRU	86.03	59.39
w/o CNN	85.68	61.02
w/o BiLSTM	86.03	59.16
Mô hình đè xuất	**86.61**	**59.67**

TÀI LIỆU THAM KHẢO

[1] Aspect-based sentiment analysis for software requirements elicitation using fine-tuned Bidirectional Encoder Representations from Transformers and Explainable Artificial Intelligence

[2] CABiLSTM-BERT: Aspect-based sentiment analysis model based on deep implicit feature extraction

[3] Detecting depression: employing word-embeddings and sentence transformers